인공지능 팩트체크는 편향된 정보처리에 대한 해답이 될 수 있는가?

팩트체크 출처, 신념 일치, 디지털 미디어 리터러시의 영향*

김연주 한림대학교 건강과 뉴미디어 연구센터 연구교수**
노기영 한림대학교 미디어스쿨 특훈교수***

본 연구는 팩트체크 출처가 인간의 편향된 정보처리를 최소화할 수 있는 방안을 모색하고자, 다양한 팩트체크 출처가 뉴스 신뢰도에 미치는 영향을 온라인 실험을 통해 검증하였다. 구체적으로, 팩트체크 출처(인간 전문가, AI, 크라우드소싱)에 따른 뉴스 수용자들의 뉴스 기사 신뢰도 차이를 알아보았으며, 팩트체크 메시지가 기존 신념과 일치하거나 충돌할 때 그 효과가 어떻게 달라지는지를 살펴보았다. 아울러 수용자들의 디지털 미디어 리터러시(DML) 수준이 이러한 효과를 어떻게 조절하는지 분석하였다. 연구 결과, 인공지능과 크라우드소싱 기반 팩트체크가 인간 전문가보다 더 효과적으로 확증 편향을 줄일 수 있음을 확인하였다. 특히, 디지털 미디어 리터러시 수준이 높은 사람들일수록 인공지능 기반 팩트체크의 확증편향 약화 효과가 더욱 두드러졌다. 본 연구는 인공지능과 집단지성이 수용자들의 편향된 정보처리를 완화하고 허위 정보를 줄이는 데 중요한 역할을 할 수 있음을 시사한다.

KEYWORDS 허위정보, 팩트체크, 인공지능, 인간 전문가, 크라우드소싱, 뉴스 신뢰도, 확증 편향

---

* 이 논문은 2022년 대한민국 교육부와 한국연구재단의 지원을 받아 수행된 연구임(NRF-2022S1A5C2A03091539).

** mkj99@hallym.ac.kr, 제1저자

*** gnoh@hallym.ac.kr, 교신저자

1. 서론

디지털 미디어 환경은 정보의 접근성과 유통 속도를 극적으로 증가시켰지만, 이러한 환경은 동시에 허위정보(disinformation)와 가짜 뉴스의 확산을 촉진하는 역할을 하고 있다(O'Connor & Weatherall, 2019; Southwell & Thorson, 2015). 특히, 소셜 미디어 플랫폼을 통해 전파되는 잘못된 정보는 개인의 인식뿐만 아니라 공공 신뢰도에도 심각한 영향을 미치며, 이는 단순한 혼란을 넘어서 민주주의와 공공 의사결정 과정에까지 부정적인 결과를 초래할 수 있다(Allcott & Gentzkow, 2017; Bennett & Livingston, 2018). 이러한 문제를 해결하기 위해 다양한 시회적 주체들, 예를 들어 언론매체, 소셜 미디어 플랫폼, 학술 기관 등이 허위 정보에 대응하고 있으며(Amazeen, 2020; Scheufele & Krause, 2019), 그중 팩트체크(fact-checking)는 매우 중요한 대응 수단으로 자리 잡았다. 팩트체크는 전통적으로 언론사와 같은 전문 기관에 의해 주도되어 왔다. 그러나 디지털 환경의 발전과 함께 팩트체크의 방식과 출처가 다양해지며, 새로운 논의가 활발히 이루어지고 있다. 최근에는 인공지능(AI)과 크라우드소싱을 포함한 다양한 팩트체크 방식이 도입되고 있으며, 각각의 방식은 독특한 강점과 한계를 가지고 있다. 예를 들어, 인공지능 기반 팩트체크는 방대한 데이터를 신속하고 효율적으로 분석할 수 있는 능력을 통해 허위 정보를 식별하는 데 활용되고 있다. 구글의 "ClaimReview" 시스템은 기계 학습 알고리즘을 사용해 뉴스와 소셜 미디어 콘텐츠를 분석하고, 허위 정보 가능성이 높은 콘텐츠를 자동으로 플래그 처리하여 경고를 제공한다(Potthast, Kiesel, Reinartz, Bevendorff, & Stein, 2017). 이는 인간의 개입을 최소화하며, 방대한 정보를 처리하는 데 있어 강력한 도구로 평가받고 있다. 반면, 크라우드소싱 기반 팩트체크는 일반 대중이 팩트체크 과정에 참여하도록 유도하여 집단지성을 활용하는 접근법이다. 페이스북은 논란이 되는 게시물에 대해 추가적인 사실 확인 정보를 제공하는 '관련 기사' 기능을 도입하여, 사용자가 허위 정보에 쉽게 노출되는 것을 방지하려는 노력을 기울였다(Smith, Jackson, & Raj, 2017, 12, 21). 이러한 방식은 대중의 집단지성을 활용하여 팩트체크의 범위를 넓히는 동시에, 정보의 투명성을 강화하려는 시도로 평가받고 있다. 이처럼 다양한 팩트체크 방식은 각각의 강점과 한계를 지니며, 기술과 참여가 결합된 새로운 모델의 가능성을 제시하고 있다. 그러나 팩트체크는 항상 성공적이지 않으며, 때로는 오히려 역효과를 초래할 수 있다. 일부 연구에 따르면 팩트체크 메시지는 허위 정보를 바로잡지 못할 뿐만 아니라, 사람들이 오히려 허위 정보에 더 강한 믿음을 가지게 만드는 경향이 있다(Walter & Tukachinsky, 2020). 이러한 역효과는 인간의 정보처리 과정에서 나타나는 동기화된 추론(motivated reasoning) 때문으로 설명될 수 있다

(Lewandowsky, Ecker, Seifert, Schwarz, & Cook, 2012; Nielson & Graves, 2017). 사람들은 종종 사실 자체보다 자신의 기존 신념이나 당파적 정체성에 근거해 정보를 평가하려는 동기를 가지며(이은주 · 김현석 · 이종민, 2023; Shin, Jian, Driscoll, & Bar, 2018; Tsang, 2021; Weeks & Garrett, 2014), 이러한 경향은 팩트체크 메시지의 수용 여부에 영향을 미친다. 특히, 개인이 자신의 정치적 입장과 모순되는 정정 메시지를 접했을 때, 이를 거부하는 경향이 강하다. 학자들은 이러한 동기화된 추론이 팩트체커의 노력을 약화시키고, 결과적으로 여론의 양극화를 악화시킨다고 주장하지만, 이에 대한 실증 연구는 아직 부족한 실정이다.

허위 정보에 대응하기 위한 팩트체크의 필요성은 그 어느 때보다 절실하며, 이를 통해 대중이 보다 정확하고 신뢰할 수 있는 판단을 내릴 수 있도록 돕는 것은 매우 중요하다. 팩트체크는 소셜 미디어 플랫폼과 뉴스 매체에서 허위 정보의 확산을 억제하는 주요 수단으로 기능하고 있으나, 그 효과는 메시지의 출처에 따라 다르게 나타날 수 있다. 특히, 수용자가 팩트체크 메시지의 출처를 어떻게 인식하는가는 정보 수용 과정 전반에 중대한 영향을 미치며, 이는 정보처리 방식 및 뉴스의 신뢰도에 있어서 유의미한 차이를 초래할 수 있다(Graves, 2016). 최근에는 특히 인공지능(AI) 기반 팩트체크가 주목받고 있다. 인공지능 기반 팩트체크는 방대한 데이터를 신속하고 효율적으로 분석할 수 있으며, 인간의 주관이 개입되지 않는 객관적 정보처리 방식으로 평가받고 있다(Moon, Chung, & Jones-Jang, 2023; Waddell, 2019).

인공지능은 인간보다 더 많은 데이터를 처리할 수 있고, 이를 통해 정확성을 보장하는 측면에서 강력한 도구로 자리 잡고 있지만, 이러한 인공지능 기술이 모든 정보 수용자에게 동일한 방식으로 신뢰를 얻는 것은 아니다. 수용자들의 디지털 미디어 리터러시(Digital Media Lieracy, DML) 수준에 따라 인공지능 기반 팩트체크의 신뢰도와 수용도는 달라질 수 있으며, 이는 팩트체크의 효과성에도 중요한 영향을 미친다. 디지털 미디어 리터러시는 개인이 디지털 미디어 환경에서 정보를 비판적으로 평가하고, 그 신뢰성을 판단하는 능력을 의미한다(Livingstone, 2004). 디지털 미디어 리터러시가 높은 사람들은 정보 출처에 대한 신뢰성 평가 능력이 뛰어나며, 팩트체크의 결과를 더욱 객관적으로 받아들일 가능성이 높다. 반면, 리터러시가 낮은 사람들은 인공지능 기반 정보나 자동화된 시스템에 대한 신뢰도가 낮아 팩트체크 메시지를 덜 신뢰할 가능성이 있다. 이는 특히 확증편향(confirmation bias)과 밀접한 관련이 있다. 확증편향이란 개인이 자신의 기존 신념과 일치하는 정보를 더 신뢰하고, 그렇지 않은 정보를 거부하는 경향을 의미한다(Kunda, 1999). 확증편향은 허위 정보에 대한 교정을 어렵게 만드는 주요한 심리적 장벽으로 작용하며, 특

히 정치적 신념이나 이념에 대한 강한 견해를 가진 수용자들에게 더욱 두드러지게 나타난다(Weeks & Garrett, 2014). 이러한 맥락에서 팩트체크 출처가 어떻게 확증편향을 완화할 수 있는지, 특히 AI와 같은 자동화된 시스템이 기존 신념과 상충하는 정보를 제공할 때 수용자들이 이를 어떻게 받아들이는가에 대한 연구는 중요하다.

본 연구는 AI 기반 팩트체크가 확증편향을 약화시킬 수 있는 잠재력을 가지고 있으며, 특히, 디지털 미디어 리터러시가 높은 수용자들이 AI를 통한 정보를 더 객관적으로 받아들일 가능성이 크다는 가설을 바탕으로 진행되었다. 이러한 연구는 팩트체크의 출처가 인공지능, 인간 전문가, 크라우드소싱 등으로 구분되었을 때, 수용자들이 그 정보를 어떻게 처리하고, 결과적으로 뉴스 신뢰도에 미치는 영향을 살펴본다. 특히, 디지털 미디어 리터러시 수준에 따라 인공지능 기반 팩트체크가 확증편향을 얼마나 완화할 수 있는지를 분석하고자 한다. 따라서 본 연구는 다음과 같은 연구 질문을 제기한다. 첫째, 팩트체크 출처가 정보처리 과정에 미치는 영향은 무엇인가? 둘째, 인공지능 기반 팩트체크가 인간 전문가나 크라우드소싱을 통한 팩트체크보다 확증편향을 줄이는 데 얼마나 효과적인가? 셋째, 디지털 미디어 리터러시 수준이 팩트체크 효과에 어떤 영향을 미치는가? 이러한 연구 문제를 해결함으로써 팩트체크 출처에 따른 정보처리 과정의 차이를 규명하고, 인공지능이 제공하는 객관적 정보가 허위 정보를 바로잡는 데 얼마나 효과적인지에 대한 시사점을 제공하고자 한다.

2. 이론적 논의

1) 허위 정보에 대한 팩트체크 효과

고의적인 속임수를 유도하는 허위 정보(disinformation)는 의도와 상관없이 잘못된 정보가 전달되는 오정보/잘못된 정보(즉, misinformation)와 구별된다는 점에서 학문적으로 중요한 개념이다(Lazer et al., 2018). 본질적으로 잘못된 정보가 대중에게 전달되면서 오해를 불러일으키고, 이는 의도하지 않은 결과로 발생하기도 하지만, 특정 이해관계를 가진 개인이나 단체에 의해 조직적으로 확산 되기도 한다. 이러한 현상은 정보 환경 전반에 걸쳐 신뢰를 약화시키고, 사회적 소통을 왜곡하는 문제로 이어질 수 있다. 특히, 현대사회의 디지털 기술과 소셜 미디어의 발달은 허위 정보의 확산 속도를 급격히 증가시켰다. 소셜 미디어 플랫폼은 정보의 전파와 재생산을 가속화하는 구조적 특징을 가지고 있어 허위 정보가 폭발적으로 확산되기에 적합한 환경을 제공한다. 예를 들어, 알고리즘은 사용자 관심

사를 기반으로 정보를 큐레이션하며, 이러한 과정에서 허위 정보가 더욱 빈번하게 노출될 가능성을 높인다(Cinelli et al., 2020). 감정적으로 자극적이거나 놀라운 내용을 포함한 허위 정보는 사용자들에 의해 더 널리 공유되며(Bright, 2016), 개인의 기존 신념과 가치관에 부합할 경우 허위 정보는 더 쉽게 수용되는 경향을 보인다. 이러한 정보는 확증편향(confirmatory bias)을 통해 기존 신념을 강화하며, 대중이 이를 비판적으로 검토하기보다는 자신의 관점에 맞는 정보를 무비판적으로 수용할 가능성을 높인다(Nyhan & Reifler, 2010). 그 결과, 정보 생태계 내에서 대중 간의 이견이 심화되고, 정치적 양극화와 같은 사회적 갈등이 더욱 악화될 가능성이 크다(Garrett, Nisbet, & Lynch, 2019). 이러한 허위 정보의 확산은 개인 차원의 혼란을 넘어 사회 전반의 신뢰와 안정성을 훼손할 수 있다. 예컨대, 건강, 정치, 환경 등 다양한 사회적 이슈에서 잘못된 의사결정을 초래하여 공공 정책의 효과적인 실행을 저해하는 장애물이 될 수 있다(Lewandowsky, Ecker, & Cook, 2017). 나아가, 지속적으로 확산되는 허위 정보는 언론, 정부 기관, 학문적 권위에 대한 신뢰를 약화시켜 사회적 신뢰 구조를 근본적으로 흔드는 결과를 초래한다(Bovet & Makse, 2019).

뉴스의 허위 정보에 대한 근본적인 해결책은 뉴스를 접하는 수용자 개인의 의식과 허위 정보를 분별하는 능력을 기르는 것이다. 다시 말해, 개인이 비판적 사고를 통해 정보의 진위를 스스로 판단하는 자정 작용이 필요하다. 이러한 허위 정보의 대응책으로 거론되는 것 중 하나가 정보의 팩트체크이다. 팩트체크는 뉴스의 허위정보를 확인하고 교정해 주는 저널리즘의 형태로서, 메시지 수용자들이 정보의 진위를 더 정확하게 평가할 수 있도록 돕는다. 팩트체크는 사전 검증(Amazeen, 2020; Lewandowsky & van der Linden, 2021)부터 반박/정정(Chung & Kim, 2021; Kligler-Vilenchik, 2021)에 이르기까지 다양한 형태로 사용되고 있다. 이러한 과정은 수용자들에게 올바른 정보에 접근할 수 있는 기회를 제공하며, 허위 정보로 인한 혼란을 줄이는 데 기여한다. 특히, 팩트체크는 유권자들의 식견을 키우고(Flynn, Nyhan, & Reifler, 2017) 정치인들이 진실한 발언을 하도록 압박하는 데 효과적(Nyhan& Reifler, 2015)이라는 연구 결과들이 발표되면서 허위정보 노출에 대응할 수 있는 하나의 대안으로 여겨져 왔다. 선행 연구들 역시 팩트체크가 수용자들의 잘못된 인식이나 신념을 교정하는 데 유의미한 역할을 한다는 점을 입증했다(Fridkin, Kenney, & Wintersieck, 2015; O'Sullivan & Geiger, 1995). 이렇게 팩트체크는 잘못된 믿음을 바로잡고 허위정보의 확산을 막기 위한 주요 도구로 주목받고 있지만(Zhang, Featherstone, Calabrese, & Wojcieszak, 2021), 최근까지 그 효과에 대한 논란이 끊이지 않고 있다(Walter & Tukachinsky, 2020). 일부 연구들은 팩트체크가 모든 상황에서 효과적이지 않을 수 있으며, 특정 조건에서는 오히려 역효과를 초래할 수 있다고 지적하고 있다(Walter

& Tukachinsky, 2020). 특히, 허위 정보와 정치적 성향 간의 상호작용에 주목하는 연구들은, 허위 정보에 대한 정정 노력이 수용자의 기존 신념과 일치하지 않을 경우 효과가 제한되거나, 심지어 기존 신념을 더 강화시키는 역효과가 발생할 수 있다고 주장한다(Garrett et al., 2013; Lewandowsky & van der Linden, 2021; Nyhan & Reifler, 2010). 예를 들어, 수용자들이 정치, 경제, 오락과 같은 주제에 대한 올바른 정보를 팩트체크를 통해 제시받았을 때, 해당 정보가 자신의 기존 신념과 상반되는 경우, 수용자들은 자신의 의견을 쉽게 바꾸지 않으며, 때로는 기존 신념이 더욱 강화되는 현상을 보였다(Park, Kang, & Cha, 2021; Torson, 2016). 수용자들은 팩트체커의 정치적 성향에 따라 팩트체크 메시지를 선택적으로 신뢰했으며, 이는 팩트체크 메시지가 기존 신념에 반하는 경우 심리적 저항이 발생함을 의미한다(Krause, Freiling, Beets, & Brossard, 2020). 즉, 사람들은 자신의 기존 신념과 일치하지 않는 팩트체크 메시지에 심리적 저항을 느끼며, 이는 팩트체크 메시지를 신뢰하지 않고 오히려 자신의 신념을 강화하려는 동기를 부여한다. 따라서 팩트체크가 수용자에게 효과적으로 작용하려면, 단순히 사실을 제공하는 것만으로는 부족하며, 수용자의 신념 체계와의 일치 여부에 따라 팩트체크 접근법이 달라져야 할 필요성이 있다. 이렇듯 팩트체크 메시지의 설득효과에 허위정보에 대한 신념의 일치여부가 영향을 미친다면, 최적의 효과를 낼 수 있는 팩트체크 방안에 대해 고민할 필요성이 존재한다.

2) 허위 정보와 동기화된 추론에 의한 편향적 정보처리

팩트체크 메시지에 대한 한가지 설명은 동기화된 추론(motivated reasoning)에서 출발한다. 이 이론은 정보의 신뢰도에 대한 개인의 편향된 평가를 설명하기 위해 제안되었으며(Arieli, Amit, & Mentser, 2018; Slater & Rouner, 1996), 개인이 정보처리 과정에서 특정 목표를 설정하고 그 목표를 유지하려는 노력을 의미한다. 동기화된 추론은 두 가지 동기로 나눌 수 있는데, 하나는 자신이 원하는 목표를 유지하고자 하는 방향성 동기(direction motivation)이고, 다른 하나는 객관적인 결론에 도달하고자 하는 정확성 동기(accuracy motivation)이다. 이 이론은 개인이 어느 정도의 정확성을 지향하는 동기를 가질 수 있지만 일반적으로 개인의 정보처리는 정확성을 지향하기보다는 목표 지향적이라고 가정한다(Taber & Lodge, 2006). 새로운 정보를 평가할 때 개인은 기존의 신념을 유지하려는 경향이 강하며(Pennington & Hastie, 1992), 자신의 신념과 일치하지 않는 정보는 피하거나 무시하려는 경향이 존재한다(Garrett et al., 2013; Lewandowsky et al., 2012; Park et al., 2021). 이러한 동기화된 추론은 인지 부조화 이론(cognitive dissonance theory)으로도 설명할 수 있다(Festinger, 1957). 예를 들어, 개인의 기존 신념과 새로운 정보 사이에 불일치

가 발생할 때, 이는 인지적 불편함을 초래하며(Cacciatore et al., 2014), 이때 사람들은 불편한 감정을 줄이기 위해 기존 신념을 유지하려는 경향을 보인다(de Vreese et al., 2018).

정치적 정보처리의 맥락에서 동기화 추론은 더욱 목표지향적으로 나타난다(Margolin, Hannak, & Weber, 2018). 이 과정에서 개인은 세 가지 주요 편향적 정보처리 현상을 보인다. 첫째, 확증 편향으로 자신의 신념을 강화시켜주는 정보만을 접하여 다른 사람들도 비슷한 신념을 가지고 있을거라 인식한다. 둘째, 자신의 신념과 반대되는 정보를 거부하는 반증 편향이다. 셋째, 사전 태도 효과(prior attitude effect)로, 개인은 자신의 신념과 일치하는 정보를 더 신뢰하고, 그렇지 않은 정보는 더 의심하고 불신한다. 이 과정에서 가장 두드러진 현상 중 하나는 확증 편향(confirmation bias)이다. 확증 편향은 자신의 기존 신념을 강화하는 정보만을 선택적으로 받아들이는 경향으로, 개인은 자신이 이미 가지고 있는 신념, 가치, 의견과 일치하는 정보를 선호하며, 반대되는 정보는 거부하거나 비판적으로 검토하는 반증 편향(disconfirmation bias)을 보인다(Lodge & Taber, 2013). 이러한 정보처리 경향은 선택적 노출(selective exposure), 선택적 지각(selective perception), 선택적 파지(selective retention)로 나타나며, 개인은 자신의 기존 신념을 강화하는 정보에 노출되고, 그 정보를 본인의 관점에 맞게 해석하며, 기존 신념에 부합하는 정보를 더 오래 기억하려는 경향을 보인다(Kunda, 1999). 즉, 수용자들은 자신의 기존 신념과 일치하는 정보를 더 신뢰하고 수용하는 반면, 기존 신념과 불 일치하는 정보는 더 면밀히 검토할 뿐만 아니라 불신한다.

이러한 동기화된 추론은 다양한 집단 간의 관계와 행동을 설명하는 사회 정체성 이론(Hogg & Reid, 2006)으로도 설명할 수 있다. 사회 정체성 이론에 따르면, 개인은 자신을 특정 집단과 동일시하며(Terry & hogg, 1996), 의사결정 시 내집단과 외집단을 구분한다(Gaertner et al., 2013; Jones-Jang & Noland, 2022; Margolin et al., 2018).

사람들은 자신의 신념을 유지하기 위해 의도적으로 합리화된 추론을 보여주며, 새로운 정보의 수용은 메시지 자체의 내용보다는 정치적 성향이나 기존의 태도에 의해 좌우된다(Ecker & Ang, 2019). 예를 들어, 자신의 정치적 신념과 일치하는 뉴스 헤드라인을 읽은 사람들은 신념과 일치하지 않는 헤드라인을 접한 사람들보다 해당 뉴스 기사를 더 신뢰하는 경향이 있다(Kim & Dennis, 2019). 마찬가지로, 사람들이 자신이 지지하는 정당에 대한 긍정적인 메시지에 대해 더 높은 신뢰도를 보인 반면, 반대 정당을 비판하는 메시지에 대해서는 낮은 신뢰도를 보였다(Lazer et al., 2018). 또한, 최근 연구에서는 팩트 체크에 메시지의 효과가 수용자들의 당파성에 따라 달라지는 것으로 나타났다(Walter, Cohen, Holbert, & Morag, 2020). 이는 사람들이 자신의 기존 신념과 일치하는 팩트체크 메시지

를 더 신뢰하는 경향이 있다는 것을 시사한다. 이상의 논의를 종합하면, 사람들은 팩트체크 메시지의 판정 결과에 대해 확증 편향을 보이며, 자신의 기존 신념과 일치하는 정보는 더 신뢰하고, 반대되는 정보는 더 비판적으로 받아들일 가능성이 높다.

연구가설 1. 기존 신념과 일치하지 않는 뉴스 기사를 읽은 사람들은, 기존 신념과 일치하는 뉴스 기사를 읽은 사람들보다 해당 뉴스 기사에 대한 신뢰도가 낮을 것이다.

3) 팩트체크와 정보원의 효과

팩트체크의 주요 원칙은 권위 있는 출처를 기반으로 허위 주장을 검증하고 정정하는 것이다(Vinhas & Bastos, 2022). 팩트체크는 공식적인 통계자료, 과학적 연구, 전문가집단, 그리고 AI와 같은 다양한 정보원을 활용하여 이루어진다(Moon et al., 2023; Nieminen & Sankari, 2021). 특히, 팩트체크에서 정보원(source)의 효과는 저널리즘, 교육, 마케팅, 정치 캠페인 등 다양한 분야에서 오랜 연구의 대상이 되어왔으며(Chen, Teng, Yu, & Yu, 2016; Dou, Walden, Lee, & Lee, 2012; Hu & Sundar, 2010; Huang & Sundar, 2022; Kim & Lee, 2021, 2023; Moon et al., 2023), 팩트체크는 단순히 주장을 검토하는 것에 그치지 않고, 근거를 바탕으로 이를 검증하고 설명하는 과정을 거친다. 이러한 과정은 정보원의 역할이 매우 중요하지만, 동시에 복잡하고 시간이 많이 소요되는 작업임을 시사한다(Vinhas & Bastos, 2022).

팩트체크 작업이 노동집약적이고 효율성이 떨어질 수 있다는 점 때문에, 팩트체크의 효율성을 높이기 위한 자동화 시스템 구축에 대한 관심이 증가하고 있으며, AI와 같은 대체 팩트체킹 소스의 활용 가능성이 주목받고 있다(Moon et al., 2023; Waddell, 2018, 2019). 그러나 팩트체크 효과는 정보원의 신뢰성과 깊은 관련이 있으며, 누가 정보를 제공하느냐에 수용자의 메시지에 대한 인식이 달라질 수 있다(Pennycook & Rand, 2019; van der Meer & Jin, 2020). 정보원이 명시된 경우 팩트체크 메시지의 정정 효과는 더 강해지며, 출처는 정보의 신뢰도를 판단하는 데 핵심적인 요소로 작용한다(Pennycook & Rand, 2019; Tsang, 2021; Vraga & Bode, 2018). 또한, 허위정보에 대한 교정효과는 팩트체크 주체를 더 신뢰할수록 더 커지는 경향을 보였다(Guillory & geraci, 2013; Walter et al., 2021).

하지만 기존 연구들은 특정 정보원이 팩트체크 메시지의 편향성을 줄이는 데 다른 정보원보다 더 효과적인지에 대해 충분한 검토가 이루어지지 않았다. 따라서 본 연구는 팩트팩트체크를 수행하는 정보원(Source)에 초점을 맞추고, 그 정보원이 메시지 수용자에게 미치는 영향을 알아보고자 한다. 구체적으로 본 연구는 다음의 세 가지 정보원인 인공지

능, 전문가 집단, 크라우드소싱이 수용자가 팩트체크 메시지를 처리하는 방식에 어떠한 차이를 보이는가를 체계적으로 검증하고자 한다.

(1) 팩트체크 주체로서 인공지능 vs 인간 전문가에 대한 인식

국내외를 막론하고 주로 전문가, 정부 기관 및 언론사는 오랫동안 신뢰할 수 있는 팩트체크 출처로 간주되었으나, 일부 연구들은 팩트체크 메시지 수용 과정에서 인간 전문가(human experts)의 잠재적 의도나 동기를 의심하는 경향이 존재한다고 밝혔다(Margolin et al., 2018; Slater & Rouner, 1996). 특히, 당파적 성향의 사람들은 자신의 정치적 신념을 위협하는 주장을 펼치는 인간 전문가에 대해 더 큰 불신을 나타낼 가능성이 높다(Leeper & Slothuus, 2014). 이는 전문가가 제공하는 정보에 대한 전반적인 의심과 반지성주의적 경향으로 이어져(Merkley, 2020), 인간 전문가가 제공하는 팩트체크 메시지는 정치적 의도나 신뢰성에 대한 의심으로 인해 수용이 저해될 수 있다.

반면, 인간 전문가의 한계가 드러나면서 인공지능(AI)과 같은 대체 팩트체크 출처에 대한 관심이 크게 증가하고 있다(Martínez-Carrillo-& Tamul, 2019; Nguyen et al., 2018). 인공지능은 새로운 정보를 생성하기보다는 기존 정보에서 사실을 선별하고 정리하는 역할을 하지만, 인간 전문가와 달리 의도나 동기를 의심받지 않으며, 사람들은 인공지능을 독립적이고 신뢰할 수 있는 팩트체커로 인식하는 경향이 있다. 이는 인간 행위자의 역할을 기계가 대신할 수 있다는 CASA(computers are social actors) 패러다임과 일맥상통하며(Reeves & Nass, 1996), 인공지능이 사람보다 더 객관적이고 편견이 적다고 인식되는 현상을 설명해 준다. 특히, 최근 대중의 인공지능에 대한 기대는 더욱 높아지고 있으며, 팩트체크 맥락에서 인공지능은 데이터 기반의 분석을 통해 정보를 객관적으로 검증할 수 있다는 신뢰를 형성한다(Wu, 2020). 팩트체크 맥락에서 인공지능은 미리 입력된 알고리즘과 데이터베이스를 기반으로 정보를 분석하며, 새로운 데이터를 창출하기보다는 기존 데이터의 진위 여부를 확인하는 역할을 한다(Wu, 2020). 이는 인공지능이 감정을 배제한 논리적 처리 과정을 통해 사실에 기반한 결정을 내릴 수 있다는 신뢰를 형성한다(Sundar, 2008). 특히, 논란이 많은 주제에서 인공지능이 제공하는 팩트체크는 정치적 의도가 없다는 인식 때문에 더욱 객관적이고 신뢰할 수 있는 정보로 여겨지는 경향이 있다(Banas et al., 2022).

MAIN(modality-agency-interactivity-navigability) 모델에 따르면, 사람들은 어림짐작 처리, 즉 기계 휴리스틱(machine heuristic)을 통하여 인공지능이 생산한 콘텐츠를 공정하고 정확하다고 간주하는 경향이 있다(Sundar, 2008). 이는 인간보다 기계가 편향되지 않고 더 객관적일 것이라는 기대에서 비롯되며, 결과적으로 인공지능이 생성하거나 큐레

이션한 뉴스는 독자들로부터 더 신뢰할 수 있는 정보로 받아들여진다(Sundar & Nass, 2001). 인공지능은 인간이 가질 수 있는 편향을 배제하고, 뉴스 선택 과정에서 객관성을 보완할 수 있다(Wu, 2020). 이러한 연구들은 인공지능이 작성한 팩트체크 메시지가 인간 전문가가 작성한 메시지보다 더 신뢰받을 수 있음을 시사한다. 이는 인공지능이 개인적 의도를 가지지 않는다는 인식 때문으로 메시지에 대한 저항을 덜 유발하기 때문이라고 해석된다(Chen et al., 2016; Kim & Lee, 2021).

이와 같은 경향은 논란이 많은 주제에서 더욱 두드러지며, 인공지능이 생성한 콘텐츠는 인간이 제공한 정보보다 더 신뢰할 수 있다는 기대감으로 인해 높은 신뢰도를 얻게 된다(Banas et al., 2022). 또한, 사람들이 기계 휴리스틱에 더 강하게 의존할수록 인공지능이 제공하는 팩트체크 메시지를 더 신뢰하는 경향이 선행 연구에서 확인되었다(Banas et al., 2022; Moon et al., 2003). 따라서, 인공지능이 팩트체크 과정에서 편견이 적고 객관적이라는 인식이 강하게 작용하며, 특히 논란이 있는 주제에 대해 인공지능이 제공하는 정보가 신뢰받을 가능성이 높다는 점에 주목해야 한다. MAIN 모델에 따르면, 사람들은 기계 휴리스틱을 통해 인공지능이 생성한 정보를 더 신뢰할 수 있다고 판단하며(Sundar, 2008), 이는 인공지능이 제공하는 정보가 편향되지 않고 객관적일 것이라는 기대에서 기인한다. 인공지능이 제공하는 팩트체크 정보에 대한 신뢰도는 특히 정보 출처가 인공지능일 때 더욱 높아지며, 결과적으로 수용자들의 동기화된 추론을 줄일 수 있다. 이러한 관점에서 본 연구는 다음과 같은 가설을 도출하였다.

연구가설 2. 팩트체크 출처가 인간 전문가인 경우, 팩트체크 메시지가 기존 신념과 일치하지 않는 정보를 반박할 때, 기존 신념과 일치하는 정보를 반박하는 경우보다 뉴스 기사에 대한 신뢰도가 감소할 것이다.

연구가설 3. 팩트체크 출처가 인공지능인 경우, 팩트체크 메시지가 기존 신념과 일치하지 않는 정보를 반박할 때와 기존 신념과 일치하는 정보를 반박하는 경우의 뉴스 기사에 대한 신뢰도의 차이를 보이지 않을 것이다.

(2) 크라우드 소싱

또 다른 팩트체크 정보원으로 크라우드 소싱이 있다. 크라우드소싱은 여러 사람이 네트워크를 통해 협력하여 정보를 검증하는 과정으로 정의되며(Howe, 2006), 이 방법은 동기화된 추론에 덜 영향을 받을 수 있다. 크라우드소싱이 동기화된 추론에 덜 영향을 미치는 이유는 정보 출처를 다르게 인식하게 함으로써 사용자들의 인식을 변화시키는 데 있다. 썬다

와 나스(Sundar & Nass, 2001)는 다양한 온라인 정보 출처를 권위 있는 출처, 기술적 출처, 집단적 출처, 그리고 자기 자신을 정보 출처로 사용하는 방식으로 구분했다. 크라우드소싱은 이 중 집단적 출처로 분류될 수 있으며, 이는 사용자들이 정보 제공자들을 다수의 협력자로 인식하도록 만든다.

정보 출처의 신뢰도는 일반적으로 두 가지 주요 요소로 평가되는데, 이는 전문성과 신뢰성이다(Hovland & Weiss, 1951). 전문성은 정보 출처가 지닌 지식이나 경험의 수준을 의미하며, 신뢰성은 출처가 편향되지 않고 진실한 정보를 제공하려는 의도를 의미한다. 그러나 크라우드소싱 사이트의 정보 출처의 전문성을 평가하는 것은 쉽지 않다(Metzger, Flanagin, & Medders, 2010). 많은 경우 정보 제공자들은 익명 사용자이거나 가명을 사용하는 경우가 많으며, 그들의 신원을 확인하기 어렵다(Heilman et al., 2011). 하지만, 크라우드소싱의 집단적 출처 성격은 다수의 사용자가 협력하고 지속적으로 정보를 감시, 수정하는 시스템을 통해 신뢰성을 확보할 수 있게 한다. 다수의 협력자가 오류를 수정하고 정보를 업데이트하는 과정이 내재되어 있기 때문에, 사용자들은 크라우드소싱 정보가 편향되지 않고 공정하다는 인식을 가질 가능성이 높다(Terwiesch & Xu, 2008).

사용자들은 대개 다수의 의견을 신뢰하고 그 판단을 따르는 경향이 있으며, 이는 밴드왜건 효과(bandwagon effect)로 설명된다(Sundar, Jia, Waddell, & Huang, 2015). 예를 들어, 다른 사용자들의 평가가 많은 뉴스 기사는 더 신뢰할 수 있는 정보로 평가될 가능성이 높으며, 클릭 가능성도 높아진다(Xu, 2013). 보건 분야에서도 팔로워 수가 많은 트위터 계정이 더 신뢰할 수 있는 정보 출처로 인식되는 경향이 나타났다(Lee & Sundar, 2013). 이는 다수의 사용자들이 관여한 정보가 더 객관적이고 신뢰할 수 있다는 인식을 형성하게 하는 요인으로 작용한다.

크라우드소싱의 개방형 콘텐츠 시스템은 집단적 모니터링 메커니즘을 동반하고 있으며, 많은 사용자가 정보를 감시하고 오류를 수정하는 과정을 통해 정보의 신뢰성을 높인다(de Laat, 2014). 이는 사용자들에게 편향된 의견이 사이트를 지배할 가능성이 적으며, 정보가 다양한 관점을 반영한다고 인식하게 한다. 그러나, 크라우드소싱 팩트체킹 메시지가 무조건 신뢰를 받는 것은 아니다. 예를 들어, 위키피디아(Wikipedia)와 같은 크라우드소싱 사이트는 누구나 편집할 수 있기 때문에 신뢰도에 대한 의심을 받기도 한다(Lucassen & Schraagen, 2012). 사용자들은 이러한 사이트가 편향된 정보나 악의적인 수정의 가능성에 대해 걱정할 수 있으며(Metzger et al., 2010), 이는 크라우드소싱 정보에 대한 불신을 불러일으킬 수 있다.

그럼에도 불구하고, 선행연구에 따르면 크라우드소싱 단서는 사회적 압력이나 밴드

왜건 효과를 통해 유용성, 인기도, 또는 사회적 규범을 나타내어 동기화된 추론을 줄이는 역할을 할 수 있다고 밝혔다(Messing & Westwood, 2014). 특히, 소셜 미디어 사용자들의 집단지성은 다양한 신념과 지식을 반영하여 편견이 적고 공정한 팩트체크로 인식될 가능성이 있다(Barnett, Boddupalli, Nundy, & Bates, 2019). 또한, 크라우드소싱 팩트체크는 메시지의 신뢰도를 높이거나(Giudice, 2010), 팩트체크 메시지에 대한 반발을 줄이는 것으로 나타났다(Huang & Sundar, 2022).

이러한 점을 바탕으로, 본 연구는 크라우드소싱 팩트체크가 기존의 전문가 집단에서 나타나는 확증 편향을 줄여줄 수 있을 것 이라고 가정한다. 즉, 팩트체크의 출처가 크라우드소싱인 경우, 사용자는 기존 신념과 일치하지 않는 정보를 반박하는 메시지에도 더 높은 신뢰도를 부여할 가능성이 있으며, 기존 신념과 일치하는 정보와 일치하지 않는 정보 사이의 신뢰도 차이가 감소할 것이다.

연구가설 4. 팩트체크의 출처가 크라우드소싱인 경우, 팩트체크 메시지가 기존 신념과 일치하지 않는 정보를 반박할 때와 기존 신념과 일치하는 정보를 반박하는 경우의 뉴스 기사 신뢰도의 차이는 감소할 것이다.

4) 팩트체크 메시지 처리 과정에서의 디지털 미디어 리터러시의 역할

디지털 미디어 환경에서 팩트체크는 허위 정보 확산을 방지하고, 정보의 신뢰성을 평가하는 데 중요한 역할을 한다. 특히, 최근에는 인공지능 기반 팩트체크의 역할이 더욱 주목받고 있다. 인공지능은 방대한 양의 데이터를 빠르게 분석하고, 신뢰할 수 있는 정보를 선별하는 데 효과적이기 때문에 팩트체크의 효율성을 높일 수 있다(Moon et al., 2023; Waddell, 2019). 그러나 인공지능 기반 팩트체크 메시지가 모든 수용자에게 동일한 영향을 미치는 것은 아니며, 특히 디지털 미디어 리터러시(digital media literacy) 수준에 따라 그 효과는 달라질 수 있다.

디지털 미디어 리터러시는 개인이 디지털 미디어를 비판적으로 이해하고, 정보를 평가하고 분석하는 능력을 의미한다(Livingstone, 2004). 디지털 미디어 리터러시가 높은 사람들은 정보를 평가하는 능력이 더 발달 되어 있으며, 정보 출처의 신뢰성을 판단하는 데 중요한 역할을 한다(염정윤 · 정세훈, 2019). 반면, 디지털 미디어 리터러시가 낮은 사람들은 인공지능 기반 팩트체크 메시지에 대한 신뢰도가 상대적으로 낮을 수 있다. 이러한 수용자들은 인공지능과 같은 새로운 기술에 대한 이해도가 낮고, 정보의 출처가 인공지능일 때 그 신뢰성을 의심할 가능성이 있다(Hovland & Weiss, 1951). 또한, 이들은 인공지능 기

반 메시지가 제공하는 정보를 사람이나 전문가가 제공한 정보보다 덜 신뢰할 가능성이 크다(Liu & Wei, 2018). 인공지능 기반 팩트체크 메시지가 디지털 미디어 리터러시 수준에 따라 다르게 수용되는 이유는, 디지털 미디어 리터러시가 높은 사람들은 인공지능의 객관성과 효율성을 더 높이 평가하기 때문이다. 이들은 인공지능이 개인적 의도가 없고, 기계적 알고리즘을 통해 정보를 제공하는 점을 긍정적으로 인식한다(Sundar, 2008). 이러한 인식은 뉴스의 신뢰도 감소 효과(news credibility reduction effect)를 더욱 강화할 수 있다. 즉, 디지털 미디어 리터러시가 높은 사람들은 인공지능이 제공하는 팩트체크 메시지로 인해 뉴스의 신뢰도가 더 크게 감소할 수 있는 반면, 리터러시가 낮은 사람들은 이러한 효과를 덜 경험할 수 있다.

디지털 미디어 리터러시와 인공지능 기반 팩트체크의 관계는 허위 정보와 팩트체크 사이의 연관성에서도 드러난다. 허위 정보는 사회에 잘못된 정보를 확산시킬 위험성을 지니고 있지만, 팩트체크는 이를 막는 주요 도구로 기능한다(박기묵, 2018). 디지털 미디어 리터러시는 허위정보와 팩트체크를 구별하고, 정보의 신뢰성을 평가하는 데 중요한 역할을 한다. 기존 연구에 따르면, 디지털 미디어 리터러시가 높은 사람들은 미디어 시스템 전반에 대해 비판적인 시각을 가지며, 정보의 신뢰성을 더욱 엄격하게 평가하는 경향을 보인다(Ashley, Poepsel, & Willis, 2010). 이는 특히 논쟁적인 이슈를 다룰 때 뉴스와 정보 출처에 대해 더 신중하고 비판적인 태도를 유발할 수 있다(Johnson & Eagly, 1989). 그러나 디지털 미디어 리터러시가 높은 사람들이 모든 정보를 무조건 적으로 신뢰하지는 않는다. 디지털 미디어 리터러시가 높을수록 가짜뉴스에 노출될 가능성도 함께 증가할 수 있다(염정윤 · 정세훈, 2018). 이는 미디어 이용 능력이 정보에 대한 비판적 사고를 증진 시키는 동시에, 다양한 온라인 활동을 통해 더 많은 정보에 노출될 가능성을 높이기 때문이다(Livingstone & Helsper, 2010). 디지털 능력이 높은 사람들이 유해 콘텐츠나 허위 정보에 더 자주 노출될 수 있다는 연구 결과도 존재한다(Livingstone, Ólafsson, & Staksrud, 2013).

하지만 디지털 미디어 리터러시가 높은 사람들은 미디어 시스템 전반에 대해 비판적인 시각을 가지고 있으며, 뉴스에 대해 더 부정적인 평가를 내릴 가능성이 크다(Ashley, Poepsel, & Willis, 2010). 이들은 뉴스의 정확성을 더욱 엄격하게 평가하며, 특히 논쟁적인 이슈를 다룰 때 뉴스의 편향성을 더 강하게 지각하는 경향을 보인다(Johnson & Eagly, 1989). 따라서 디지털 미디어 리터러시가 높은 수용자는 뉴스와 팩트체크의 신뢰성을 평가할 때, 허위 정보와 팩트체크 뉴스를 구별하는 능력이 더 뛰어날 가능성이 크다. 반면, 디지털 미디어 리터러시가 낮은 사람들은 허위 정보에 노출되더라도 이를 구별하지 못할 가능성이 높다.

인공지능 기반 팩트체크 메시지가 디지털 미디어 리터러시 수준에 따라 다르게 작용한다는 주장은 디지털 미디어 리터러시가 정보 수용과 신뢰도 형성에 중요한 역할을 한다는 선행 연구에 기초하고 있다(Livingstone, 2004; McGrew, 2020). 디지털 미디어 리터러시가 높은 사람들은 미디어 정보를 비판적으로 평가하고 정보 출처의 신뢰성을 보다 정확하게 판단할 수 있는 능력이 뛰어나다. 특히, 인공지능 기반 시스템이 제공하는 정보는 자동화된 데이터 분석과 객관성에 의해 기존 신념에 반하는 정보조차 더 쉽게 수용될 수 있도록 한다(Tiernan, Costello, Donlon, Parysz, & Scriney, 2023). 이러한 과정에서 디지털 미디어 리터러시가 높은 사람들은 인공지능을 통한 정보의 객관성을 신뢰하기 때문에 확증편향이 약화될 가능성이 크다. 인공지능 기반 팩트체크 메시지는 주관적 의도를 배제하고, 객관적 알고리즘에 기반해 정보를 제공하는 시스템으로 인식될 수 있으며, 이는 디지털 미디어 리터러시가 높은 사람들에게 특히 더 신뢰를 받을 수 있다(Sundar, 2008). 이로 인해 신뢰가 높아지면 기존 신념에 의존하는 정도가 줄어 확증편향이 약화될 수 있다. 반면, 디지털 미디어 리터러시가 낮은 사람들은 인공지능 기반 팩트체크 메시지를 덜 신뢰할 가능성이 있으며, 따라서 기존 신념을 유지하는 경향이 더 강하게 나타날 수 있다.

결과적으로, 디지털 미디어 리터러시가 높은 사람들은 인공지능이 제공하는 정보의 객관성을 신뢰하며, 기존 신념에 반하는 정보를 더 쉽게 수용하는 경향이 있다(Tiernan et al., 2023). 이는 인공지능 팩트체크가 디지털 미디어 리터러시가 높은 사람들 사이에서 확증편향을 약화시키고 궁극적으로 뉴스에 대한 신뢰도 평가에 대한 차이를 더욱 감소시킬 수 있음을 시사한다. 반면, 디지털 미디어 리터러시가 낮은 사람들은 인공지능 기반 팩트체크 메시지에 대한 신뢰도가 낮기 때문에 이러한 효과를 덜 경험하게 될 가능성이 크다.

연구가설 5. 뉴스 신뢰도에 대한 인공지능 팩트체크 메시지를 통한 확증 편향의 약화는 디지털 미디어 리터러시 수준이 높은(vs 낮은) 사람들에게 더 크게 나타날 것이다.

3. 연구 방법

1) 실험 설계

본 연구의 실험은 2024년 7월 22일부터 7월 31일까지 진행되었으며, 참가자는 전국 20세 이상의 성인남녀를 대상으로 KBS를 통해 성별, 연령별, 지역별 인구분포에 비례하도록 층화표집 했다. 본 연구는 정치적으로 편향된 메시지의 정보처리를 다루고 있기 때문에 정치

성향이 중도인 사람들은 모집에서 제외하여 총 960(남성 50.6%, 연령 M = 44.90, SD = 12.86)명이 실험에 참가하였다. 실험 참가자의 월평균 가구 소득은 400만 원에서 600만 원 사이였고, 학력의 평균은 '대학졸업' 이었다.

온라인 실험은 '3(팩트체크 출처: 인공지능(AI) vs 인간 전문가 vs 크라우드 소싱) × 2(신념 일치 vs 불일치)의 혼합설계로 진행되었다. 참가자들은 6개의 피험자 간 집단에 무작위로 배치된 후 보편적 의료 서비스(찬성 vs 반대)에 대한 뉴스 기사를 읽었다. 의료 서비스 논조의 뉴스 기사에 노출된 사람들 중 같은 의견을 지닌 사람들을 신념 일치 조건으로(n = 476), 다른 의견을 지닌 사람들을 불일치 조건으로(n = 484) 분류하였다. 그런 다음 실험 참가자들은 펙트체크 출처인 인간 전문가(n = 324), 인공지능(n = 317), 크라우드소싱(n = 319) 중 한 가지에 할당되어 팩트체크 메시지를 읽었다. 참가자들은 팩트체크 메시지를 읽은 후 설문에 응답하였으며, 마지막으로 본 실험의 목적 및 실험 처치에 관한 설명을 제공받고 실험을 종료하였다. 연령, 성별, 가구 소득, 학력에 따른 무작위 할당의 효과를 확인하기 위해 일원 배치 분산분석(one-way ANOVA)을 실시한 결과, 그룹 간의 차이가 나타나지 않았다(p = .166). 이에 더해 본 실험과 관련이 있는 요인인 피험자들의 기계 휴리스틱(machine heuristic)에 대한 집단 간 차이를 측정 한 결과, 유의미한 차이가 없는 것으로 밝혀졌다(p = .685).

2) 실험 자극물

실험 자극물은 실제 상황을 반영하는 뉴스 기사를 선택하기 위해 100명의 대학생 그룹을 대상으로 한국의 뉴스 헤드라인 후보 4개(운동선수 병역기피, 보편적 의료서비스, 코로나 백신 부작용, 국토보유세인상)를 사전 테스트 하였다. 이 사전테스트의 주요 목적은 페니쿡과 랜드(Pennycook & Rand, 2021)의 온라인 가이드 라인에 따라 각각의 이슈가 오보로 간주될 가능성과 그 확산 가능성을 평가하는 것이다. 이 중 보편적 의료 서비스(M = 4.93, SD = 1.03, t(99) = 9.12, p < .001)가 가장 높은 점수를 받아 실험물로 최종 선정되었다. 첫 번째 허위 정보 게시물은 보편적 의료 서비스에 대한 필요성 및 효용성에 관한 찬성의 논조로 작성된 내용이고, 두 번째 허위 정보 게시물은 보편적 의료 서비스에 대한 논란과 부작용에 관한 반대의 논조로 작성된 내용이다. 팩트체크 메시지는 팩트체크의 주체(인간 전문가, 인공지능, 크라우드소싱)가 사실확인의 검증 작업을 수행한 결과를 명시했고, 상단과 하단에 출처를 표시하였다(〈그림 1〉).

그림 1. 팩트체크 출처에 따른 자극물 예시

3) 측정

(1) 신념 일치와 불일치 조건

신념 일치 여부를 측정하기 위해, 참가자에게 보편적 의료 서비스에 관한 신문 기사에 대한 생각이 얼마나 일치하는지 질문하였다(1= 나는 보편적 의료 서비스에 반대한다, 2= 나는 보편적 의료 서비스에 대해 의견이 없다, 3= 나는 보편적 의료 서비스를 찬성한다). 신념 일치 조건(N= 476)에는 보편적 의료 서비스에 찬성 의견을 지닌 응답자가 의료 서비스

찬성과 관련된 뉴스에 노출된 경우를 포함하고, 신념 불일치 조건(N= 484)에는 보편적 의료 서비스 반대 의견을 지닌 응답자가 의료 서비스 반대와 관련된 기사에 노출된 경우를 포함하여 재코딩하였다.

(2) 디지털 미디어 리터러시

디지털 미디어 리터러시를 측정하기 위해, 참가자들에게'매우 동의하지 않는다(1) ~ 매우 동의 한다(7)'까지 7점 척도로 동의 정도를 평가하도록 하여 디지털 미디어 리터러시를 평가하였다. 측정 문항은 '나는 다양한 미디어 환경의 뉴스와 정보를 비교할 수 있다', '나는 디지털 미디어 메시지의 정확성에 대해 판단할 수 있다', '나는 디지털 미디어 콘텐츠가 개인에게 미치는 긍정적 · 부정적 영향을 분석할 수 있다', '나는 디지털 미디어 매체의 신뢰성, 신뢰도, 객관성, 유용성 등을 판단할 수 있다', '나는 디지털 미디어 콘텐츠로 인한 위험과 결과로부터 자신을 방어할 수 있다'로 측정하였다(Timmers & Glas, 2010; Mils et al., 2014)(M = 3.84, SD = 1.06, α = .92).

(3) 뉴스 신뢰도

뉴스 기사의 신뢰도를 측정하기 위해 참가자들에게 '매우 동의하지 않는다(1) ~ 매우 동의 한다(7)'까지 7점 척도로 동의 정도를 평가하도록 요청하였다. 신뢰도의 평가는 내가 읽은 뉴스 기사의 내용은 '신뢰할 수 있다', '공정하다', '편향적(역코딩)', '심층적', '정확하다'로 측정하였다(Appelman & Sundar, 2016)(M = 3.42, SD = 1.27, α = .89).

4. 결과

1) 조작 점검

가설 검증에 앞서, 실험의 처치에 대한 확인을 위해 조작 점검(manipulation check)을 실시 하였다. 먼저, 뉴스 기사의 논조를 확인하기 위해 각각의 뉴스 기사가 보편적 의료 서비스에 찬성 또는 반대 입장을 어느 정도 반영하고 있는가를 질문하였다(1 = 보편적 의료 서비스 반대~7 = 보편적 의료 서비스 찬성). 분석 결과, 보편적 의료 서비스 찬성 기사(M = 5.87)를 읽은 사람들이 반대 기사(M = 2.21)를 읽은 사람보다 기사의 내용이 보편 의료 서비스에 더 찬성 한다고 지각하는 것으로 나타났다[t(648) = 15.29, p < .001].

다음으로, 펙트체크 주체의 조작 여부를 확인하기 위해 참가자들에게 각각의 팩트체

크 메시지를 제시한 후, 해당 메시지 작성자가 누구인지 물었다. 분석 결과, 인공지능 집단 참가자의 96%가 인공지능, 인간 전문가 집단 참가자의 95%가 인간 전문가, 크라우드 소싱 집단 참여자의 89%가 크라우드 소싱이라고 응답하여 실험 조작이 성공적으로 이루어졌음을 확인할 수 있었다[$\chi^2(4) = 765.31$, $p < .001$].

2) 가설 검증

본 실험은 피험자 간 요인과 피험자 내 요인을 모두 포함하는 3(팩트체크 출처: 인공지능(AI) vs 인간 전문가 vs 크라우드 소싱) × 2(신념 일치 vs 불일치)의 혼합 설계를 채택하였다. 디지털 미디어 리터러시는 조절변인으로 포함하였다. 수집된 데이터는 혼합효과(maximum likelihood) 회귀모형을 사용하여 분석하였고, 조절 효과 분석에는 Process Model 3을 적용하였다. 분석 과정에서는 디지털 미디어 리터러시의 특정 수준을 기준으로 조절 효과를 평가하였으며, 구체적으로 $M + 1SD$(높음) 및 $M - 1SD$(낮음) 수준에서 결과를 제시하였다.

가설 1은 참가자들이 자신의 기존 신념과 일치하는 정보를 뉴스 기사를 읽을 경우, 신념과 불일치하는 뉴스 기사를 읽은 경우보다 뉴스 기사에 대한 신뢰도가 높을 것이라고 예측했다. 분석 결과, 기존 신념과 일치하는 뉴스 기사를 읽은 참가자들($M = 4.32$, $SD = 0.70$)은 기존 신념과 일치하지 않는 뉴스 기사를 읽은 참가자들($M = 3.70$, $SD = 0.81$)보다 뉴스 기사에 대한 신뢰도가 유의미하게 높았다[$t(958) = 7.64$, $p < .001$]. 참가자들은 자신의 기존 신념과 반대되는 정보를 접하면 기존 신념을 더 강화하는 확증 편향을 보였다. 따라서, 가설 1은 지지되었다.

가설 2를 분석한 결과 예상대로, 인간 전문가 조건에서 편향된 팩트체크 메시지에 대한 처리가 유의미하게 나타났다($b = 0.31$, $SE = 0.09$, $p < .01$). 팩트체크 출처가 인간 전문가일 때, 기존 신념과 일치하지 않는 정보를 반박하는 팩트체크 메시지를 읽은 참가자들은 기존 신념과 일치하는 정보를 반박하는 메시지를 읽은 참가자들보다 뉴스 기사에 대한 신뢰도가 낮게 나타났다. 이는 자신의 신념과 불일치한 기사를 접했을 때, 팩트체크 메시지에 의해 뉴스 기사에 대한 신뢰가 더 낮아짐을 알 수 있다. 이러한 결과는 사람들이 자신의 신념에 맞는 정보를 반박하는 팩트체크 메시지를 접하면, 기존 정보를 더 신뢰하는 동기화된 추론(motivated reasoning)에 기초하고 있음을 시사한다.

다음으로 가설 3을 분석한 결과, 분석 결과, 인공지능 조건에서는 신념 일치 여부에 따른 뉴스 신뢰도 차이가 사라졌다. 즉, 팩트체크 출처가 인공지능일 때, 기존 신념과 일치하지 않는 정보를 반박하는 메시지를 읽은 사람들과 신념 일치 정보를 반박하는 메시지를

표 1. 신념일치, 팩트체크 출처, 디지털 리터러시 수준이 뉴스 신뢰도에 미치는 영향

		뉴스 신뢰도 (Y)	
		b	*SE*
상수		4.23***	0.09
변수	신념 일치(vs 불일치) (a)	-0.34**	0.08
	AI(vs 인간 전문가) (b1)	-0.31**	0.09
	크라우드소싱(vs 인간 전문가) (b2)	-0.33**	0.09
	디지털 미디어 리터러시 (C)	-0.08	0.08
상호작용항	일치 × AI(vs 인간 전문가)	-0.41**	0.07
	일치 × 크라우드소싱(vs 인간 전문가)	-0.38**	0.01
	일치 × 디지털 미디어 리터러시	-0.03	0.01
	AI × 디지털 미디어 리터러시	-0.24*	0.01
	크라우드소싱 × 디지털 미디어 리터러시	-0.08	0.01
	일치 × AI × 디지털 미디어 리터러시	0.46**	0.01
	일치 × 크라우드소싱 × 디지털 미디어 리터러시	0.28	0.01
Total R^2 (%)		36.40	

주: 혼합효과 회귀분석 결과시 산출된 비표준화 회귀계수와 표준오차를 기술하였음. 디지털리터러시는 평균 중심화 변환을 실시했음.
*$p < .05$. **$p < .01$. ***$p < .001$.

읽은 사람들 간에 뉴스 기사에 대한 신뢰도 차이가 나타나지 않았다(b = -0.41, SE = 0.09, $p < .01$). 이러한 결과는 팩트체크의 출처가 인공지능일 때 인간 전문가에 비해 확증편향이 줄어들었음을 나타내준다. 따라서 가설 3은 지지되었다.

다음으로 팩트체크 출처가 크라우드소싱일 때, 신념 일치 여부에 따른 뉴스 기사 신뢰도 차이가 감소하는 것으로 확인되었다(b = -0.38, SE = 0.09, $p < .01$). 크라우드소싱 조건에서도 인간 전문가 집단에 비해 신념 일치 여부에 따른 차이가 감소했으며, 이는 가설 4를 지지하는 결과이다.

마지막으로 가설 5를 검증하기 위해, 개인의 디지털 리터러시 수준이 팩트체크 출처(인공지능, 인간 전문가, 크라우드소싱)의 확증편향에 미치는 영향을 조절하는가를 알아보았다. 분석 결과, 신념 일치도와 팩트체크 주체의 상호작용 효과는 개인의 디지털 미디어 리터러시 수준에 따라 다르게 나타나는 것으로 확인되었다[$F(2, 948) = 6.07$, $R^2 = .13$, $p < .01$].

그림 2. 신념 일치와 팩트체크 출처가 뉴스 신뢰도에 미치는 영향

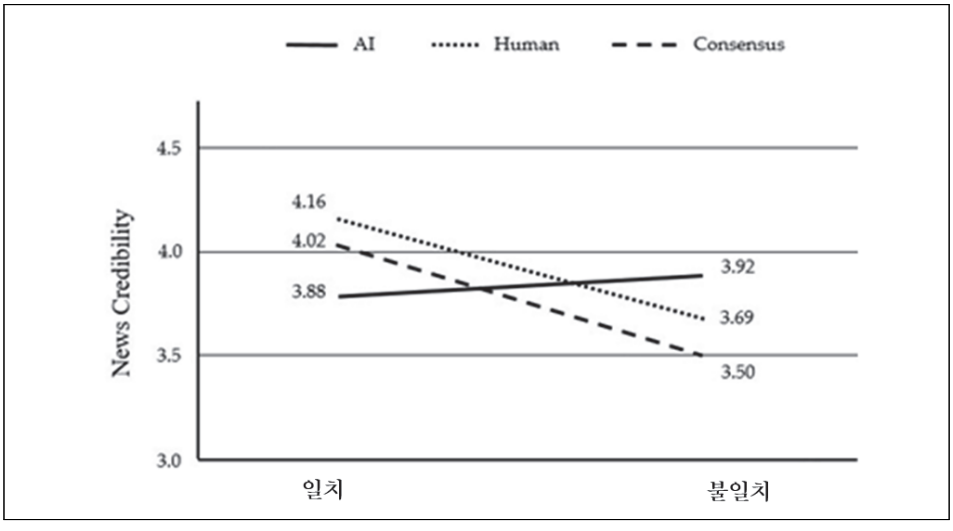

표 2. 신념 일치, 팩트체커 출처의 상호작용에 대한 디지털 리터러시 수준이 뉴스 기사 신뢰도에 미치는 조절효과

디지털 리터러시 수준		팩트체크 출처		
		인공지능	인간 전문가	크라우드소싱
상수		3.47*** (.06)	3.43*** (.06)	3.14***(.07)
변수				
디지털 리터러시 수준	높음(M + 1SD)	0.57*** (.08)	0.42*** (.06)	0.02(.04)
	낮음(M - 1SD)	0.29** (.05)	0.51*** (.07)	0.07(.04)
Total R^2(%)			36.40	

혼합효과 회귀분석 결과시 산출된 비표준화 회귀계수와 표준오차(괄호)를 기술하였음. 디지털리터러시는 평균 중심화 변환을 실시했음.

**p < .01. ***p < .001.

구체적으로 디지털 미디어 리터러시가 높은 사람들은 인공지능의 팩트체크 메시지를 신뢰하면서 기존 신념과 일치하지 않는 정보를 더 수용하는 경향이 나타났다(b = 0.57, SE = 0.08, p < .001). 이는 확증편향이 약화된 결과로 해석될 수 있다. 반면, 디지털 미디어 리터러시가 낮은 참가자들은 기존 신념에 더 강하게 의존하는 경향이 있어, 인공지능 팩트체크 메시지로 인한 신뢰도의 감소가 상대적으로 덜했다(b = 0.29, SE = 0.05, p < .01). 구체적으로, 디지털 미디어 리터러시가 높은 집단은 팩트체크 주체가 인공지능일 때

인간 전문가나 크라우드 소싱일 때 비해 확증편향이 약하게 작용했다. 또한, 이러한 경향은 특히 기존 신념에 반하는 정보가 제공될 때 두드러졌다. 따라서, 가설 5는 지지되었으며, 알고리즘 기반 팩트체크 메시지는 디지털 미디어 리터러시 수준이 높은 사람들에게 확증편향을 줄이는 역할을 하는 것을 확인할 수 있었다.

5. 결론 및 논의

본 연구는 허위 정보의 사실 확인 과정에서 동기화된 추론을 최소화할 수 있는 잠재적 해결 방안을 모색하고, 팩트체크의 효과가 메시지 출처에 따라 사람들의 정보처리에 어떤 영향을 미치는지에 초점을 맞추어 탐구했다. 이를 위해, 팩트체크 정보원의 우호 여부와 동기화된 추론 관점에서 뉴스 기사와의 기존 신념의 일치 여부가 뉴스 신뢰도에 미치는 영향을 살펴보았다. 특히, 인공지능(AI), 인간 전문가, 크라우드소싱과 같은 다양한 팩트체커(fact-checker)가 정보 이용자들이 메시지를 어떻게 수용하고, 그에 따른 뉴스 신뢰도를 어떻게 평가하는지를 분석하였다. 또한, 이러한 정보처리 과정이 개인의 디지털 미디어 리터러시(digital media literacy) 수준에 따라 달라지는지 살펴봄으로써, 확증편향의 약화와 뉴스 신뢰도 감소를 확인하고자 했다.

연구 결과 첫째, 본 연구는 인공지능 기반 팩트체크가 확증편향을 약화시킬 수 있는 중요한 도구임을 실증적으로 밝혔다. 실험 참가자들은 기존 신념의 일치 여부에 따라 뉴스 신뢰도를 달리 평가했으며, 자신의 기존 신념과 일치하는 뉴스 기사를 일치하지 않는 뉴스 기사보다 더 신뢰하는 경향을 보였다. 하지만, 인공지능 기반의 팩트체크는 이러한 인간의 정보처리에 대한 편향을 줄여주는 것으로 확인되었다. 기존 연구에서는 팩트체크 과정이 허위 정보에 대한 인식을 오히려 강화할 수 있다는 우려가 제기되었다(Meppelink, Smit, Fransen, & Diviani, 2019). 하지만 본 연구에서는 인공지능 기반 팩트체크 메시지가 인간의 주관적 판단을 배제한 객관적 정보로 인식될 가능성을 강조하였다(McCoy, Rahman, & Somer, 2018; Liu & Wei, 2018). 이로 인해, 인공지능 팩트체크 메시지에 대한 신뢰도가 상대적으로 높게 평가되었음을 본 연구를 통해 확인할 수 있었다. 결과적으로, 인공지능 팩트체크 메시지를 접한 사람들은 기존 신념과 일치하지 않는 정보라 할지라도 더 쉽게 수용할 수 있었으며, 기존 신념에 의존하는 확증편향이 약화될 가능성이 큰 것으로 나타났다. 특히, 디지털 미디어 리터러시 수준이 높은 집단에서 이러한 경향이 두드러졌으며, 이들은 인공지능 기반 팩트체크 메시지로 인해 뉴스 신뢰도가 더욱 크게 감소한 것으로 확인되었

다. 이러한 결과는 인공지능이 제공하는 정보가 확증편향을 약화시키는 역할을 할 수 있음을 시사한다.

둘째, 크라우드소싱을 통한 팩트체크의 역할 또한 주목할 만한 결과를 보여주었다. 크라우드소싱은 다수의 의견을 모아 팩트체크를 수행하는 방식으로, 인공지능과 마찬가지로 인간 전문가에 비해 사용자들이 더 객관적이고 신뢰성 있는 정보를 제공한다고 인식될 수 있다. 이는 다수의 사람들이 참여하여 검증한 정보가 개인적 판단이나 특정 이해관계로부터 자유롭다고 여겨지기 때문이다. 크라우드소싱의 이러한 특징은 사회적 압력과 밴드왜건 효과에 민감하게 반응하는 사용자의 특성을 반영한다. 밴드왜건 효과란 다수의 의견에 동조하려는 경향을 의미하며, 다수의 사람들이 참여하여 검증한 정보는 개인에게 더욱 신뢰할 만한 것으로 인식될 수 있다. 이러한 결과는 크라우드소싱 팩트체크가 단순히 개인적인 의견이 아니라, 다양한 의견들이 종합된 객관적이고 신뢰할 수 있는 정보로서 기능할 수 있음을 시사한다. 크라우드소싱을 통해 얻은 정보는 그 자체로 더욱 공정하고 신뢰할 만한 정보로 판단될 가능성이 높으며, 이는 전통적인 정보원이 점점 분산되고 있는 가운데, 집단지성이 새로운 정보 출처로 떠오르고 있다는 기존 연구(Chung, 2017, 2019; Messing & Westwood, 2014)와 일치한다.

또한, 크라우드소싱을 통한 팩트체크는 참여자의 수가 많을수록 편견을 줄이는 효과를 가진다. 다수의 참여자가 검증한 정보는 개인적인 편견이나 특정한 의도에 의해 왜곡되지 않았다고 판단되기 때문에, 객관적이고 신뢰할 만한 정보로 인식된다. 이는 크라우드소싱이 정보 검증 과정에서 객관성을 높이는 중요한 역할을 한다는 점을 보여준다.

그러나 크라우드소싱 방식은 다수의 의견이 항상 옳다는 보장이 없기 때문에, 정확성과 신뢰성을 완벽하게 보장하지 못할 수 있는 한계도 존재한다. 복잡하거나 논쟁적인 주제에서는 다수의 의견이 오히려 편향된 방향으로 작용할 가능성도 있기 때문에, 이러한 크라우드소싱의 딜레마가 나타날 수 있다. 그럼에도 불구하고, 본 연구는 크라우드소싱 팩트체크가 객관성과 신뢰성을 강화하는 데 기여할 수 있음을 입증했으며, 이는 중요한 시사점을 제공한다.

셋째, 본 연구는 디지털 미디어 리터러시의 중요성을 다시 한번 강조하였다. 디지털 미디어 리터러시가 높은 사람들은 정보를 비판적으로 평가하는 능력이 뛰어나며, 정보의 출처에 대한 신뢰성을 더 엄격하게 판단한다. 이러한 리터러시 수준은 인공지능 기반 팩트체크 메시지에 대한 신뢰도를 높이며, 인공지능이 제공하는 팩트체크 메시지를 더 신뢰할수록 사람들은 자신의 기존 신념을 재평가하는 경향이 강하게 나타났다. 이는 인공지능이 제공하는 정보가 객관적이고 중립적이라는 인식에서 비롯된 것으로, 리터러시가 높은 사

람들은 인공지능의 판단을 신뢰하고 그 정보를 더 쉽게 받아들였다. 반면, 디지털 미디어 리터러시가 낮은 사람들은 인공지능 팩트체크 메시지를 통해 자신의 신념을 재평가하려는 경향은 적었다. 이러한 결과는 디지털 미디어 리터러시가 인공지능 기반 팩트체크 메시지의 효과를 결정짓는 중요한 요인임을 시사한다. 즉, 리터러시가 높은 사람들은 인공지능의 객관성을 인지하고 이를 기반으로 정보를 수용하며, 기존 신념을 재조정하려는 성향이 나타나는 것으로 확인되었다.

따라서, 향후 디지털 미디어 리터러시 교육을 강화하는 것이 인공지능 기반 팩트체크를 통해 허위 정보를 보다 효과적으로 차단할 수 있는 중요한 방법이 될 수 있다. 리터러시가 높아질수록 사람들은 정보의 출처를 더 정확하게 평가하고, 객관적인 정보를 수용하는 능력이 향상되기 때문에, 인공지능 기반 팩트체크의 효과도 함께 증가할 것이다.

본 연구는 정보의 사실 확인 과정에서 동기화된 추론에 대한 실증적 증거를 제공할 수 있다. 동기화된 추론은 사람들이 자신이 동의하지 않거나 믿고 싶지 않은 정보를 거짓 정보로 인식하는 경향을 말하며(Egelhofer & Lecheler, 2019), 이는 잘못된 정보에 대한 사실 확인 과정에서 큰 장애물이 될 수 있다. 본 연구는 이러한 동기화된 추론을 줄이는 효과적인 방법으로 인공지능 기반 팩트체크를 제시하며, 잘못된 정보로 인한 피해를 줄이기 위한 이론적 및 실무적 시사점을 제공한다.

첫째, 인공지능 기반 팩트체크는 동기화된 추론을 줄이는 데 중요한 역할을 할 수 있다. 인공지능 기술은 방대한 데이터를 자동으로 처리하여 빠르고 정확하게 사실을 검증할 수 있는 장점을 가지고 있으며, 이를 통해 뉴스 신뢰성을 높이거나 허위 정보의 신뢰성을 감소시키는 데 효과적일 수 있다. 이 결과는 객관적이고 정확한 성과가 중요한 작업에서 사람들이 인간 에이전트보다 기계 에이전트를 더 신뢰한다는 선행 연구와도 일치하는 결과이다(Sundar & Kim, 2019). 즉, 사람들은 특정 집단에 유리하거나 불리한 특정 정치적 동기가 없는 공정한 에이전트로 인공지능을 인식하고, 따라서 인공지능의 사실 확인 메시지를 보다 균형 잡힌 방식으로 처리한다. 이러한 연구 결과는 양극화된 정보처리로 인해 발생하는 다양한 사회 문제와 갈등을 해결하는 데 인공지능이 도움이 될 수 있다는 낙관적인 전망을 제시한다(McCoy et al., 2018). 또한, 정치적 편견으로부터 정보를 보호하면서 사실 확인 정보를 효과적으로 전파할 수 있는 방법에 대한 이해를 제공한다.

둘째, 크라우드소싱 팩트체크는 다수의 의견을 기반으로 편향된 정보를 걸러내는 데 유용하며, 다수의 사용자가 검증한 정보를 통해 사회적 신뢰를 구축하는 데 중요한 역할을 한다. 따라서 사용자 참여형 검증 시스템이 개발된다면 허위 정보에 대한 대응이 더욱 강화될 것으로 기대해 볼 수 있다. 특히, 크라우드소싱 출처가 정치적으로 편향된 팩트체크

메시지의 처리를 줄이는 데 미치는 영향력은 기존의 전통적인 정보원(기자단, 매스미디어 전문가)의 힘이 분산되고 있는 상황에서 더욱 두드러지며, 집단지성이 새로운 정보원이 될 수 있음을 시사한다. 이러한 발견은 인간의 의견이 편향된 것으로 인식되더라도 메시지 출처에 대한 신뢰도가 크게 손상되지 않음을 실증적으로 보여줄 수 있을 것으로 기대된다.

셋째, 인공지능 기반 팩트체크 도구는 이상적으로 디지털 미디어 리터러시 수준이 높은 사람들에게 가장 효과적으로 사용될 수 있지만, 디지털 미디어 리터러시 수준은 사람마다 다르다는 점을 인식해야 한다. 고령자, 저소득층, 낮은 학력을 가진 사람들은 일반적으로 디지털 리터러시가 낮아 인공지능 장치나 인공지능이 생성한 팩트체크 정보를 수용하는 데 주저할 가능성이 높다(Güneş & Bahçivan, 2018). 즉, 중요한 것은 고도로 자동화된 팩트체크 솔루션 자체가 아니라, 메시지 처리 과정에서 발생하는 현상이다. 따라서 인공지능 기반 팩트체크는 정보처리 과정에서 나타나는 편견과 오류를 줄이는 데 기여할 수 있으며, 이러한 효과는 디지털 미디어 리터러시가 높을수록 더욱 극대화될 수 있다. 디지털 미디어 리터러시가 높은 사람들은 인공지능이 제공하는 정보의 객관성을 인식하고 더 쉽게 수용할 가능성이 크며, 이는 확증편향을 줄이는 데 중요한 역할을 할 수 있다.

이러한 시사점에도 불구하고 본 연구는 다음과 같은 한계점을 지니고 있다. 첫째, 본 연구에서 사용된 뉴스는 가상의 이야기로 구성되었기 때문에 실제 뉴스 환경에 대한 일반화 가능성이 제한될 수 있다. 또한, 일부 참가자들이 실험 전 유사한 뉴스에 노출되었을 가능성을 배제할 수 없으며, 실험물로 사용된 내용에 대한 사전지식은 피험자들의 응답에 영향을 미칠 수 있는 가능성이 존재하므로 향후 연구에서는 이에 대한 고려가 필요하다고 판단된다. 둘째, 본 연구는 특정 주제를 중심으로 진행되었기 때문에, 다양한 주제(정치적 이슈, 사회적 이슈, 과학적 이슈)에서 팩트체커의 역할이 달라질 가능성을 고려한 연구가 필요하다. 특히, 복잡한 과학적 문제나 사회적 논쟁에서 인공지능의 객관성이 더욱 중요한 역할을 할 수 있을지에 대한 추가적인 논의가 요구된다. 선행 연구(Dietvorst, Simmons, & Massey, 2015)에 따르면, 사람들이 인공지능을 사용하면서 문제를 발견했을 때, 인공지능에 대한 초기의 긍정적 인식이 부정적으로 변할 수 있기 때문에, 이러한 효과가 지속적으로 유지되는지를 탐구하는 것이 중요하다. 셋째, 본 연구에서 사용된 자극물은 팩트체크 출처(인공지능, 인간 전문가, 크라우드소싱)의 본질적 특징을 반영하도록 설계되었으나, 세 가지 자극물 간 형식적 일관성과 내용 구성 방식이 다소 상이하였다. 이는 정보원 차이에 의한 결과가 아니라 자극물의 구조적 차이에 의해 연구 결과가 영향을 받았을 가능성을 배제할 수 없게 만든다. 예를 들어, 크라우드소싱 자극물은 페이스북 사용자 여론조사를 모델로 하였으나, 위키피디아 방식과 같은 집합지성을 충분히 반영하지 못했다는 한계가

있다. 이는 크라우드소싱 기반 팩트체크의 효과를 적절히 검증하는 데 어려움을 초래했을 가능성이 있다. 향후 연구에서는 자극물 설계 단계에서 형식적 일관성을 강화하고, 파일럿 테스트를 통해 자극물의 비교 가능성을 철저히 검증할 필요가 있다. 넷째, 팩트체크 출처로 제시된 인간 전문가와 인공지능 간의 비교에서, 인간 전문가의 개인적 특성(예: 경력, 전문성)과 같은 추가적인 정보를 제공하지 않아 실험 조건 간 비교의 객관성이 다소 제한될 가능성이 있다. 이는 참가자들이 인간 전문가의 주관적 특성을 과대평가하거나, 반대로 인공지능에 대해 상대적으로 더 객관적이고 신뢰할 수 있다고 판단하게 만드는 결과를 초래할 수 있다. 따라서 향후 연구에서는 인간 전문가에 대한 이력이나 경력 정보를 실험 설계에 포함시켜, 정보원의 특성이 팩트체크 수용에 미치는 영향을 보다 체계적으로 비교할 필요가 있다. 이러한 개선은 정보원의 객관성을 높이고, 실험 결과의 타당성을 강화하는 데 기여할 수 있을 것이다. 다섯째, 크라우드소싱을 디지털 시대에서 보조적인 팩트체크 정보원으로서의 잠재적 역할을 탐구하기 위해 포함하였으나, 개념적 모호성과 설계 방식의 한계로 인해 충분히 그 효과를 검증하지 못했다는 점이 한계로 지적된다. 크라우드소싱은 기술 기반의 집단지성을 활용하여 특정 과업을 해결하는 데 초점을 맞추는 반면, 시민참여는 정책 결정과 공공 문제 해결을 위한 시민의 공식적이고 구조화된 역할에 중점을 둔다. 향후 연구에서는 크라우드소싱의 사례를 보다 명확히 정의하고, 자극물 설계에서 집합지성을 효과적으로 반영한 형식을 제시할 필요가 있다. 마지막으로 본 연구에서는 팩트체크 메시지의 내용, 톤, 스타일을 조건별로 일관되게 유지했지만, 실제 상황에서는 각 팩트체크 출처(AI, 인간 전문가, 크라우드소싱)가 고유한 커뮤니케이션 스타일을 가질 수 있다. 이러한 스타일 차이가 심리적 반응에 미치는 영향을 탐구하는 후속 연구가 필요하다. 메시지 출처의 차이가 정보처리에 미치는 영향이 다를 수 있으므로, 이를 실험 설계에 포함시켜 보다 포괄적인 시각을 제공할 필요가 있다. 이와 같은 한계에도 불구하고, 본 연구는 팩트체커의 다양한 출처를 통한 팩트체크 방안이 개인의 디지털 미디어 리터러시 수준과 뉴스에서 다루고 있는 이슈의 맥락에 따라 맞춤화될 필요가 있음을 제안하며, 미디어 실무와 공공 신뢰를 향상 시키기 위한 방향성을 제시한다.

참고 문헌

박기묵 (2018). 〈SNU 팩트체크〉를 활용한 뉴스 팩트체킹: 미디어 리터러시 가능성에 관하여. 〈사이버교육연구〉, 12권 1호, 15-22.

염정윤 · 정세훈 (2018). 가짜뉴스에 대한 인식과 팩트체크 효과 연구: 기존 신념과의 일치 여부를 중심으로. 〈한국언론학보〉, 62권 2호, 41-80.

염정윤 · 정세훈 (2019). 가짜뉴스 노출과 전파에 영향을 미치는 요인: 성격, 뉴미디어 리터러시, 그리고 이용 동기. 〈한국언론학보〉, 63권 1호, 7-45.

이은주 · 김현석 · 이종민 (2023). 사람들은 언제 팩트체크를 믿는가?: 검증 주체와 확증 편향의 영향. 〈언론정보연구〉, 60권 3호, 47-88.

Allcott, H., & Gentzkow, M. (2017). Social media and fake news in the 2016 election. *Journal of Economic Perspectives*, *31*(2), 211-236.

Amazeen, M. A. (2020). Journalistic interventions: The structural factors affecting the global emergence of fact-checking. *Journalism*, *21*(1), 95-111.

Appelman, A., & Sundar, S. S. (2016). Measuring message credibility: Construction and validation of an exclusive scale. *Journalism & Mass Communication Quarterly*, *93*(1), 59-79.

Arieli, S., Amit, A., & Mentser, S. (2019). Identity-motivated reasoning: Biased judgments regarding political leaders and their actions. *Cognition*, *188*, 64-73.

Banas, J. A., Palomares, N. A., Richards, A. S., Keating, D. M., Joyce, N., & Rains, S. A. (2022). When machine and bandwagon heuristics compete: Understanding users' response to conflicting AI and crowdsourced fact-checking. *Human Communication Research*, *48*(3), 430-461.

Barnett, M. L., Boddupalli, D, Nundy, S., & Bates, D.W. (2019). Comparative accuracy of diagnosis by collective intelligence of multiple physicians vs. individual physicians. *JAMA Network Open*, *2*(3). doi:10.1001/jamanetworkopen.2019.0096

Bennett, W. L., & Livingston, S. (2018). The disinformation order: Disruptive communication and the decline of democratic institutions. *European Journal of Communication*, *33*(2), 122-139.

Chen, J., Teng, L., Yu, Y., & Yu, X. (2016). The effect of online information sources on purchase intentions between consumers with high and low susceptibility to informational influence. *Journal of Business Research*, *69*(2), 467-475.

Chung, M. (2017) Not just numbers: The role of social media metrics in online news evaluations. *Computers in Human Behavior*, *75*, 949-957.

Chung, M. (2019). The message influences me more than others: How and why social media metrics affect first person perception and behavioral intentions. *Computers in Human Behavior*, *91*, 271-278.

Chung, M., & Kim, N. (2021). When I learn the news is false: How fact-checking information stems the spread of fake news via third-person perception. *Human Communication Research*, *47*(1), 1-24.

de Laat, P. B. (2014). From open-source software to Wikipedia: 'Backgrounding' trust by collective

monitoring and reputation tracking. *Ethics and Information Technology*, *16*(2), 157-169.

Dietvorst, B. J., Simmons, J. P., & Massey, C. (2015). Algorithm aversion: People erroneously avoid algorithms after seeing them err. *Journal of Experimental Psychology*, *144*(1), 114-126.

Dou, X., Walden, J. A., Lee, S., & Lee, J. Y. (2012). Does source matter? Examining source effects in online product reviews. *Computers in Human Behavior*, *28*(5), 1555-1563.

Ecker, U. K., & Ang, L. C. (2019). Political attitudes and the processing of misinformation corrections. *Political Psychology*, *40*(2), 241-260.

Egelhofer, J.L., & Lecheler, S. (2019). Fake news as a two-dimensional phenomenon: A framework and research agenda. *Annals of the International Communication Association*, *43*(2), 97-116.

Festinger, L. (1957). *A theory of cognitive dissonance*. Stanford, CA: Stanford University Press.

Flynn, D. J., Nyhan, B., & Reifler, J. (2017). The nature and origins of misperceptions: Understanding false and unsupported beliefs about politics. *Political Psychology*, *38*, 127-150.

Fridkin, K., Kenney, P. J., & Wintersieck, A. (2015). Liar, liar, pants on fire: How fact-checking influences citizens' reactions to negative advertising. *Political Communication*, *32*(1), 127-151.

Garrett, R. K., Nisbet, E. C., & Lynch, E. K. (2013). Undermining the corrective effects of media-based political fact checking? The role of contextual cues and naïve theory. *Journal of Communication*, *63*(4), 617-637.

Graves, L. (2016). Deciding what's true: The rise of political fact-checking in American journalism. New York, NY: Columbia University Press.

Güneş, E., & Bahçivan, E. (2018). A mixed research-based model for pre-service science teachers' digital literacy: Responses to "which beliefs" and "how and why they interact" questions. *Computers & Education*, *118*, 96-106.

Hogg, M. A., & Reid, S. A. (2006). Social identity, self-categorization, and the communication of group norms. *Communication Theory*, *16*(1), 7-30.

Hovland, C. I., & Weiss, W. (1951). The influence of source credibility on communication effectiveness. *The Public Opinion Quarterly*, *15*(4), 635-650.

Howe, J. (2006). The rise of crowdsourcing. *Wired Magazine*, *14*(6), 1-4.

Hu, Y., & Shyam Sundar, S. (2010). Effects of online health sources on credibility and behavioral intentions. *Communication Research*, *37*(1), 105-132.

Huang, Y., & Sundar, S. S. (2022). Do we trust the crowd? Effects of crowdsourcing on perceived credibility of online health information. *Health Communication*, *37*(1), 93-102.

Johnson, B. T., & Eagly, A. H. (1989). Effects of involvement on persuasion: A meta-analysis. *Psychological bulletin*, *106*(2), 290-314.

Jones-Jang, S. M., & Noland, C. (2022). The politicization of health and science: Role of political cues in shaping the beliefs of the vaccine-autism link. *Health Communication*, *37*(5), 608-616.

Kim, A., & Dennis, A.R. (2019). Says who? The effects of presentation format and source rating on fake news in social media. *Mis Quarterly*, *43*(3), 1025-1039.

Kim, Y., & Lee, H. (2021). Towards a sustainable news business: Understanding readers' perceptions of algorithm-generated news based on cultural conditioning. *Sustainability*, *13*(7), 3728. doi:10.3390/su13073728

Kim, Y., & Lee, H. (2023). The rise of chatbots in political campaigns: The effects of conversational agents on voting intention. *International Journal of Human-Computer Interaction*, *39*(20), 3984-3995.

Krause, N. M., Freiling, I., Beets, B., & Brossard, D. (2020). Fact-checking as risk communication: The multi-layered risk of misinformation in times of COVID-19. *Journal of Risk Research*, *23*(7-8), 1052-1059.

Kunda, Z. (1999). *Social cognition: Making sense of people*. Cambridge, MA: MIT press.

Lee, J. Y., & Sundar, S. S. (2013). To tweet or to retweet? That is the question for health professionals on Twitter. *Health communication*, *28*(5), 509-524.

Leeper, T. J., & Slothuus, R. (2014). Political parties, motivated reasoning, and public opinion formation. *Political Psychology*, *35*, 129-156.

Lewandowsky, S., & van der Linden, S. (2021). Countering misinformation and fake news through inoculation and prebunking. *European Review of Social Psychology*, *32*(2), 348-384.

Lewandowsky, S., Ecker, U. K., & Cook, J. (2017). Beyond misinformation: Understanding and coping with the "post-truth" era. *Journal of Applied Research in Memory And Cognition*, *6*(4), 353-369.

Lewandowsky, S., Ecker, U.K., Seifert, C. M., Schwarz, N., & Cook, J. (2012). Misinformation and its correction: Continued influence and successful debiasing. *Psychological Science in the Public Interest*, *13*(3), 106-131.

Liu, B., & Wei, L. (2018, July). *Reading machine-written news: Effect of machine heuristic and novelty on hostile media perception*. Paper presented at the 20th International Conference, HCI International 2018, Las Vegas, NV.

Livingstone, S. (2004). What is media literacy?. *Intermedia*, *32*(3), 18-20.

Livingstone, S., & Helsper, E. (2010). Balancing opportunities and risks in teenagers' use of the internet: The role of online skills and internet self-efficacy. *New Media & Society*, *12*(2), 309-329.

Livingstone, S., Ólafsson, K., & Staksrud, E. (2013). Risky social networking practices among "underage" users: Lessons for evidence-based policy. *Journal of Computer-Mediated Communication*, *18*(3), 303-320.

Lodge, M., & Taber, C. S. (2013). *The rationalizing voter*. New York, NY: Cambridge Univ.

Margolin, D. B., Hannak, A., & Weber, I. (2018). Political fact-checking on Twitter: When do corrections have an effect?. *Political Communication*, *35*(2), 196-219.

Martínez-Carrillo, N. I., & Tamul, D. J. (2019). (Re)constructing professional journalistic practice in Mexico: Verificado's marketing of legitimacy, collaboration, and pop culture in fact-checking the 2018 elections. *International Journal of Communication*, *13*, 2596-2619.

McCoy, J., Rahman, T., & Somer, M. (2018). Polarization and the global crisis of democracy: Common patterns, dynamics, and pernicious consequences for democratic polities. *American Behavioral Scientist*, *62*(1), 16-42.

Meppelink, C. S., Smit, E. G., Fransen, M. L., & Diviani, N. (2019). "I was right about vaccination": Confirmation bias and health literacy in online health information seeking. *Journal of Health Communication*, *24*(2), 129-140.

Merkley, E. (2020). Are experts (news) worthy? Balance, conflict, and mass media coverage of expert consensus. *Political Communication*, *37*(4), 530-549.

Metzger, M. J., Flanagin, A. J., & Medders, R. B. (2010). Social and heuristic approaches to credibility evaluation online. *Journal of Communication*, *60*(3), 413-439.

Moon, W. K., Chung, M., & Jones-Jang, S. M. (2023). How can we fight partisan biases in the

COVID-19 pandemic? AI source labels on fact-checking messages reduce motivated reasoning. *Mass Communication and Society*, *26*(4), 646-670.

Nguyen, A. T., Kharosekar, A., Krishnan, S., Krishnan, S., Tate, E., Wallace, B. C., & Lease, M. (2018). Believe it or not: Designing a human-AI partnership for mixed-initiative fact-checking. In *Proceedings of the 31st Annual ACM Symposium on User Interface Software and Technology* (pp. 189-199).

Nyhan, B., & Reifler, J. (2010). When corrections fail: The persistence of political misperceptions. *Political Behavior*, *32*(2), 303-330.

Nyhan, B., & Reifler, J. (2015). The effect of fact-checking on elites: A field experiment on US state legislators. *American Journal of Political Science*, *59*(3), 628-640.

O'Connor, C., & Weatherall, J. O. (2019). The misinformation age: How false beliefs spread. New Haven, CT: Yale University Press.

O'Sullivan, P. B., & Geiger, S. (1995). Does the watchdog bite? Newspaper ad watch articles and political attack ads. *Journalism & Mass Communication Quarterly*, *72*(4), 771-785.

Park, S., Park, J. Y., Kang, J. H., & Cha, M. (2021). The presence of unexpected biases in online fact-checking. *The Harvard Kennedy School Misinformation Review*, 2(1). doi:10.37016/mr-2020-53

Pennington, N., & Hastie, R. (1992). Explaining the evidence: Tests of the story model for juror decision making. *Journal of Personality and Social Psychology*, *62*(2), 189-206.

Pennycook, G., & Rand, D. G. (2019). Lazy, not biased: Susceptibility to partisan fake news is better explained by lack of reasoning than by motivated reasoning. *Cognition*, *188*, 39-50.

Pennycook, G., & Rand, D. G. (2021). The psychology of fake news. *Trends in Cognitive Sciences*, *25*(5), 388-402.

Potthast, M., Kiesel, J., Reinartz, K., Bevendorff, J., & Stein, B. (2017). A stylometric inquiry into hyperpartisan and fake news. doi:10.48550/arXiv.1702.05638

Reeves, B., & Nass, C. (1996). *The media equation: How people treat computers, television, and new media like real people and places*. Cambridge, UK: Cambridge University Press.

Scheufele, D. A., & Krause, N. M. (2019). Science audiences, misinformation, and fake news. *Proceedings of the National Academy of Sciences*, *116*(16), 7662-7669.

Shin, J., Jian, L., Driscoll, K., & Bar, F. (2018). The diffusion of misinformation on social media: Temporal pattern, message, and source. *Computers in Human Behavior*, *83*, 278-287.

Slater, M. D., & Rouner, D. (1996). How message evaluation and source attributes may influence credibility assessment and belief change. *Journalism & Mass Communication Quarterly*, *73*(4), 974-991.

Smith, J., Jackson, G., & Raj, S. (2017, 12, 21). Designing against misinformation. *Medium*. Retrieved from https://medium.com/designatmeta/designing-against-misinformation-e5846b3aa1e2

Southwell, B. G., & Thorson, E. A. (2015). The prevalence, consequence, and remedy of misinformation in mass media systems. *Journal of Communication*, *65*(4), 589-595.

Sundar, S. S. (2008). The main model: A heuristic approach to understanding technology effects on credibility. In M. J. Metzger & A. J. Flanagin (Eds), *Digital media, youth, and credibility* (pp. 72-100). Cambridge, MA: The MIT Press.

Sundar, S. S., & Kim, J. (2019). Machine heuristic: When we trust computers more than humans with our personal information. In *Proceedings of the 2019 CHI Conference on Human Factors in*

Computing Systems (pp. 1-9).

Sundar, S. S., & Nass, C. (2001). Conceptualizing sources in online news. *Journal of Communication*, *51*(1), 52-72.

Sundar, S. S., Jia, H., Waddell, T. F., & Huang, Y. (2015). Toward a theory of interactive media effects (TIME): Four models for explaining how interface features affect user psychology. In S. S. Sundar (Ed.), *The handbook of the psychology of communication technology* (pp. 47-86). Malden, MA: Wiley Blackwell.

Taber, C. S., & Lodge, M. (2006). Motivated skepticism in the evaluation of political beliefs. *American Journal of Political Scienc*e, *50*(3), 755-769.

Terry, D. J., & Hogg, M. A. (1996). Group norms and the attitude-behavior relationship: A role for group identification. *Personality and Social Psychology Bulletin*, *22*(8), 776-793.

Terwiesch, C., & Xu, Y. (2008). Innovation contests, open innovation, and multiagent problem solving. *Management Science*, *54*(9), 1529-1543.

Tiernan, P., Costello, E., Donlon, E., Parysz, M., & Scriney, M. (2023). Information and media literacy in the age of AI: Options for the future. *Education Sciences*, *13*(9), 906. doi:10.3390/educsci13090906

Tsang, S. J. (2021). Motivated fake news perception: The impact of news sources and policy support on audiences' assessment of news fakeness. *Journalism & Mass Communication Quarterly*, *98*(4), 1059-1077.

van der Meer, T. G., & Jin, Y. (2020). Seeking formula for misinformation treatment in public health crises: The effects of corrective information type and source. *Health Communication*, *35*(5), 560-575.

Vinhas, O., & Bastos, M. (2022). Fact-checking misinformation: Eight notes on consensus reality. *Journalism Studies*, *23*(4), 448-468.

Vraga, E. K., & Bode, L. (2018). I do not believe you: How providing a source corrects health misperceptions across social media platforms. *Information Communication & Society*, *21*(10), 1337-1353.

Waddell, T. F. (2018). What does the crowd think? How online comments and popularity metrics affect news credibility and issue importance. *New Media & Society*, *20*(8), 3068-3083.

Waddell, T. F. (2019). Can an algorithm reduce the perceived bias of news? Testing the effect of machine attribution on news readers'evaluations of bias, anthropomorphism, and credibility. *Journalism & Mass Communication Quarterly*, *96*(1), 82-100.

Walter, N., & Tukachinsky, R. (2020). A meta-analytic examination of the continued influence of misinformation in the face of correction: How powerful is it, why does it happen, and how to stop it?. *Communication Research*, *47*(2), 155-177.

Walter, N., Brooks, J. J., Saucier, C. J., & Suresh, S. (2021). Evaluating the impact of attempts to correct health misinformation on social media: A meta-analysis. *Health Communication*, *36*(13), 1776-1784.

Walter, N., Cohen, J., Holbert, R. L., & Morag, Y. (2020). Fact-checking: A meta-analysis of what works and for whom. *Political Communication*, *37*(3), 350-375.

Weeks, B. E., & Garrett, R. K. (2014). Electoral consequences of political rumors: Motivated reasoning, candidate rumors, and vote choice during the 2008 US presidential election. *International Journal of Public Opinion Research*, *26*(4), 401-422.

Xu, J. (2013). *Topological structure and analysis of interconnection networks* (Vol. 7). Boston, MA: Springer Science & Business Media.

Zhang, J., Featherstone, J. D., Calabrese, C., & Wojcieszak, M. (2021). Effects of fact-checking social media vaccine misinformation on attitudes toward vaccines. *Preventive Medicine*, *145*, 106408. doi:10.1016/j.ypmed.2020.106408

투고일자: 2024. 10. 15. 심사일자: 2024. 11. 14. 게재확정일자: 2024. 11. 30.

Can AI Fact-Checking Mitigate Biased Information Processing?

The Impact of Fact-Checking Sources, Belief Congruence, and Digital Media Literacy*

Yunju Kim
Research Professor, Hallym University
Ghee Young Noh
Distinguished Professor, Hallym University

This study explores whether fact-checking sources can minimize biased information processing in human cognition by examining the influence of different fact-checking sources on news credibility. To this end, an online experiment was carried out how the source of fact-checking (human experts, AI, or crowdsourcing) affected participants' trust in news articles. The study also examined how fact-checking messages aligned with or contradicted pre-existing beliefs, and how digital media literacy (DML) moderated these effects. Finding showed that AI and crowdsourcing source labels significantly reduced confirmation bias compared to human experts. Furthermore, the effect of AI-based fact-checking in weakening confirmation bias was particularly pronounced among individuals with higher levels of digital media literacy. The study proposes that both AI and collective intelligence can play a critical role in mitigating biased information processing and reducing misinformation.

KEYWORDS disinformation, fact-checking, artificial intelligence, human experts, crowdsourcing, news credibility, confirmation bias

* This work was supported by the Ministry of Education of the Republic of Korea and the National Research Foundation of Korea (NRF-2022S1A5C2A03091539)