정 보 보 호 학 회 지
제35권 제5호, 2025. 10

딥페이크 생성과 탐지 기술 동향 분석 - 위협과 대응의 기술적 진보

황 은 비*, 권 태 경**

요 약

딥페이크는 다양한 생성 기법의 등장을 통해 빠르게 발전하며 사회·보안적 주요 위협으로 부각되고 있다. 초기 딥페이크는 GAN 기반 합성이 주류를 이루며 뚜렷한 아티팩트를 남겼으나, 최근 Diffusion 기반 기법으로 전환되면서 합성 품질이 고해상도로 향상되고 흔적은 최소화되었다. 이로 인해 기존 단순 아티팩트에 의존하던 초기 탐지 방식은 한계를 드러냈다. 이에 대응해 정체성 일관성이나 시계열적 연속성과 같은 의미 단서를 활용하는 semantic 기반 탐지가 제안되었지만, 여전히 데이터셋 편중과 일반화 성능 부족 문제가 남아 있다. 본 논문은 이러한 맥락에서 딥페이크 생성을 위협, 탐지를 대응의 관점에서 2023–2025년 최신 연구 동향을 분석한다.

Ⅰ. 서 론

최근 딥페이크는 얼굴 교체(Face Swapping), 얼굴 재현(Face Reenactment), 전면 합성(Entire Face Synthesis), 얼굴 편집(Face Editing) 등 다양한 종류의 생성 기법 발전을 통해 사실성과 해상도가 크게 향상되었다. 초기에는 GAN 기반 모델들이 주류를 이루며 뚜렷한 아티팩트를 남겼으나[1,2,6,11,15] diffusion과 transformer 기반 기법의 도입으로 합성 흔적이 점점 줄어들고, 특정 인물의 정체성을 유지하거나 고해상도의 이미지를 정밀하게 합성하는 것이 가능해졌다[3-5,8-10,12-14,16-18]. 이러한 기술적 진보는 콘텐츠 제작·엔터테인먼트 등 긍정적 활용 가능성을 넓히는 동시에, 허위 정보 확산, 사생활 침해 등 사회적 혼란을 초래하는 잠재적 위협으로 부각되고 있다[18,29,30].

이에 대응하기 위해 딥페이크 탐지 기술 역시 지속적으로 발전해왔다. 초기 탐지 방법은 공간적·주파수 적영역의 비정상적 패턴을 포착하여 저수준 흔적을 찾는 artifact 기반 탐지 기법이 제안되었다[20,21]. 이후 latent space 표현 학습, 품질 열화 조건 반영, diffusion 노이즈 분포 역추적 등을 통해 실제 환경에서의 강건성을 높였으나[22-24], 최신 합성 기법에서는 합성 흔적이 점차 줄어들면서 단순 아티팩트 탐지에 의존하는 방식에는 한계가 드러났다. 이에 대응하여 얼굴 정체성 일관성이나 시계열적 연속성과 같은 의미 단서를 활용해 위조를 판별하는 semantic 기반 탐지 방식으로 발전했으며, 3D head pose 불일치[25], 프레임 간 시간적 불연속성을 포착하여[26] 탐지 성능을 개선하였다. 최근에는 forgery semantics를 분리·재구성하는 방식[27], 입력에 따라 전문가 모듈을 동적으로 선택하는 MoE-FFD[28], diffusion 모델의 복원 과정을 역으로 활용해 정체성 표현을 분리하는 DiffusionFake[29]가 제안되며, 다양한 도메인과 합성 유형에 걸쳐 일반화 성능을 강화하고 있다. 한편, 생성 기법을 아우르는 벤치마크[19]와 탐지 모델 평가를 위한 벤치마크[30,31]가 제시되면서 합성 및 탐지 성능에 대한 정량적 비교가 가능해졌다.

본 논문은 딥페이크 생성을 위협, 탐지를 대응의 관점에서 2023-2025년의 핵심 연구의 동향을 분석한다. 생성 부문은 DF40 벤치마크의 분류 체계를 따라 Face Swapping, Face Reenactment, Entire Face Synthesis, Face Editing로 구분하여 대표 기법을 분석

이 연구는 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원-대학ICT연구센터(ITRC)의 지원을 받아 수행된 연구임(IITP-2025-RS-2024-00436936, IITP-2025-RS-2020-II201602).
* 연세대학교 정보대학원 (대학원생, ebhwang95@yonsei.ac.kr)
** 연세대학교 정보대학원 (교수, taekyoung@yonsei.ac.kr)

하고, 탐지 부문은 artifact 기반과 semantic 기반으로 구분하여 대표 기법을 분석한다. 또한 통합 벤치마크 결과를 바탕으로 탐지 성능의 제약을 짚고, 이를 개선하기 위한 연구 방향을 함께 제시한다. 분석 대상은 탑티어 학회발표 논문 혹은 이 외 논문 중 인용 10회 이상을 원칙으로 선별하되, arXiv 게재 논문 중 2025년 논문은 초기 인용(≥1)이라도 저자 소속 기관을 검증한 경우 포함하였다.

Ⅱ. 딥페이크 생성 동향

[그림 1]은 딥페이크 생성 기술을 Face Swapping, Face Reenactment, Entire Face Synthesis, Face Editing의 네 가지 범주로 구분하고, 2017년부터 2025년까지 발표된 대표 연구들의 발전 흐름을 시각적으로 정리한 것이다. 본 절에서는 이 그림을 바탕으로 각 범주의 주요 기법과 특징을 살펴본다.

2.1. Face Swapping

Face swapping은 한 인물의 얼굴을 다른 인물의 얼굴로 교체하여 정체성을 바꾸는대표적인 딥페이크 생성 기법이다. 초기 기법인 Korshunova et al. [1]은 스타일 트랜스퍼개념을 도입하여 입력 얼굴의 자세·표정은 유지하면서목표 인물의 정체성과 조명 조건을 반영하는 CNN 기반 페이스 스왑 방식을 제안하였다. Content, style, lighting loss를 결합해 비교적 자연스러운 합성 결과를 얻었으나, 조명·각도 변화 취약성, 가려짐 처리등 한계가 있었다. 이후 등장한 DeepFaceLab[2]은 오픈소스 툴킷으로, H128, H256, LIAE, SAEHD 등 다양한 autoencoder/GAN 변형을 지원하고, 얼굴 검출·정렬·마스킹·합성·후처리를 통합함으로써 품질과 정체성 보존을 크게 개선하였다. 하지만, 여전히 경계선 아티팩트와 세밀한 품질 열화 문제를 완전히 해소하지는 못하였다.

최근 face swapping은 diffusion 모델을 활용해 GAN 기반 기법의 불안정성과 품질 한계를 극복하고 있다. DiffFace[3]는 ID-conditional DDPM에 외부 얼굴 파서·시선 추정기 등을 guidance로 결합해 정체성 보존과 표정·조명 유지 사이의 균형을 조절할 수 있어 합성 결과의 자연스러움이 크게 향상되었으나, 추론 속도가 느려지는 한계가 있다. REFace[4]는 face swapping을 inpainting 문제로 재정의하고 CLIP 기반으로 ID와 속성을 분리하여 head swapping까지 확장성을 확보했으며, 추론은 경량화되었으나 학습 파이프라인이 복잡해지는 단점이 있다. DreamID[5]는 Stable Diffusion Turbo를 활용해 단일 스텝 추론만으로 얼굴 합성을 수행하여 기존 diffusion 기반 기법보다 훨씬 빠른 속도를 확보하였다. 또한 Triplet ID Group(소스 얼굴, 가짜 타깃, 소스의 참조 이미지)을 구성해 모델이 정체성을 명시적으로 학습하도록 설계함으로써, 합성된 얼굴이 원본 인물과 일관된 ID를 유지하도록 했다. 이러한 설계를 통해 DreamID는 ArcFace 유사도(정체성), FID·LPIPS(영상 품질), facial landmark 보존률(표정·포즈 유지)등 주요 지표에서 기존 기법을 능가하며 state-of-the-art 성능을 보고하였다.

2.2. Face Reenactment

Face reenactment는 한 인물의 얼굴 정체성은 유지한 채, 표정과 움직임을 다른 인물의 동작에 맞게 전이하는 기법으로, 초기 연구들은 GAN과 기하학적 모델링을 기반으로 발전하였다. FSGAN[6]은 subject-

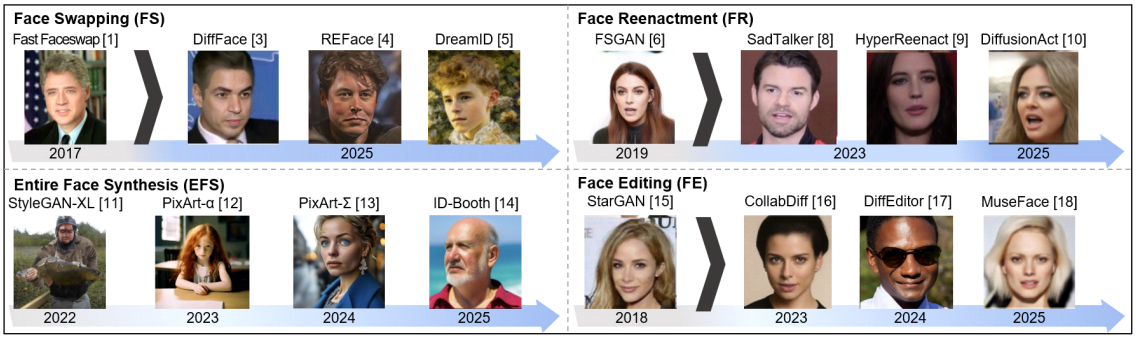

〔그림 1〕 딥페이크 생성 기법 네 가지 범주(FS, FR, EFS, FE)별 대표 연구의 발전 흐름

agnostic 방식을 통해 인물별 별도 학습 없이도 얼굴 교체와 재현이 가능하며, RNN 기반 reenactment generator와 segmentation·inpainting·blending 모듈을 결합해 포즈·표정 전이와 가려진 영역 복원을 처리하고, poisson blending loss로 경계 이질감을 줄여 시간적 일관성을 확보하였다. TPSMM[7]은 Thin Plate Spline 변환과 multi-resolution occlusion mask를 도입해 비선형 움직임과 가려진 영역을 효과적으로 처리함으로써 다양한 포즈 변화에서도 안정적 합성을 달성했으나, 극단적 변형에서는 왜곡이 발생하는 한계가 존재했다.

최근 face reenactment 연구는 오디오 기반 립싱크, 정체성과 모션의 분리 학습, diffusion 모델을 통한 시간적 일관성 강화로 발전하고 있다. SadTalker[8]는 음성 신호를 입력으로 받아 audio-to-motion 네트워크를 통해 3DMM 기반 motion coefficient(표정·포즈)를 예측하고, 이를 토대로 motion field와 3D-aware face generator를 결합해 자연스러운 talking head 영상을 합성하였다. HyperReenact[9]은 StyleGAN2 기반 generator에 appearance encoder와 pose encoder를 분리하고 hypernetwork를 적용해, one-shot 환경에서도 identity 보존과 다양한 포즈 적응성을 확보하였다. DiffusionAct[10]는 Diffusion Autoencoder와 reenactment encoder를 결합해 landmark와 gaze 조건을 반영하고, self 및 cross-subject 환경 모두에서 artifact-free의 고품질 합성을 달성하였다.

2.3. Entire Face Synthesis

Entire Face Synthesis는 Face Swapping이나 Face Reenactment처럼 실존 인물을 변형하는 것이 아니라, 존재하지 않는 새로운 얼굴 정체성을 처음부터 합성하는 기법을 의미한다. 초기 연구인 StyleGAN-XL[11]은 Projected GAN과 progressive growing을 결합해 ImageNet 규모의 데이터에서도 1024×1024 해상도의 얼굴 합성을 지원하였고, latent space 조작을 통해 나이·성별·표정과 같은 속성을 제어할 수 있었다. 그러나 학습과 추론 비용이 크고, 세밀한 영역에서 artifact가 발생하며, 동일 인물의 일관성을 유지하기 어렵다는 한계가 지적되었다.

최근 연구는 diffusion과 transformer 구조를 반영하여 효율성과 정밀 제어를 강화했다. PixArt-α[12]는 Diffusion Transformer 구조와 cross-attention 모듈을 결합하여 텍스트 조건에 따라 얼굴을 처음부터 합성할 수 있으며, 후속 연구인 PixArt-Σ[13]는 weak-to-strong training을 통해 낮은 품질 데이터에서 정제된 데이터로 점진적 학습을 수행하여 합성의 품질 성능 을 높였다. ID-Booth[14]는 사전 학습된 diffusion 모델을 기반으로, 소량의 인물 이미지를 이용한 few-shot 미세조정과 triplet identity loss를 적용하여 특정 인물의 embedding을 조건으로 활용함으로써 실존 인물과 높은 유사성을 갖는 얼굴을 합성할 수 있도록 하였다. 최근에는 이와 같이 사전 학습된 생성 모델을 개인 맞춤형으로 적응(fine-tuning)하여 특정 ID와 유사한 얼굴을 합성하는 연구들이 점차 증가하고 있으며, 단순한 가상 인물 생성에서 나아가 개인 특성을 반영하는 방향으로 발전하고 있다.

2.4. Face Editing

Face Editing은 나이, 성별, 표정, 헤어스타일 등 얼굴의 속성을 편집하는 기법으로, 기존 인물의 정체성을 유지하면서 특정 특성만 변형하는 기법이다. 초기 모델인 StarGAN[15]은 다중 도메인 간 얼굴 속성 전환을 단일 모델로 가능하게 하여, 속성 쌍마다 별도의 모델을 학습해야 했던 기존 한계를 극복하였다. 이를 통해 성별, 나이, 감정 등 전역적 속성을 하나의 네트워크로 자유롭게 전환할 수 있었다.

최근 연구는 diffusion 모델을 활용해 더 정밀한 제어와 신원 보존을 달성하는 방향으로 발전하였다. CollabDiff[16]는 사전 학습된 텍스트 기반 및 마스크 기반 diffusion 모델을 결합하여, 텍스트 프롬프트로 전역 속성을 지정하면서 동시에 마스크를 이용해 특정 영역만 수정할 수 있는 멀티모달 얼굴 편집을 지원하였다. 이어서 DiffEditor[17]는 기존 diffusion 기반 편집에서 나타난 정밀도 부족과 유연성 한계를 개선하기 위해, 텍스트 프롬프트와 함께 참조 이미지 프롬프트를 결합하였다. 이를통해 편집 영역만 수정하여 정확성과 유연성을 동시에 향상시켰으며, 객체 이동, 크기 조절, 외형 교체 등 다양한 세밀한 얼굴 편집을 지원한다. 최근 제안된 MuseFace[18]는 Text-to-Mask Diffusion Model을 통해 텍스트 입력만으로도 정밀한 객체단위 시맨틱 마스크를 자동 생성하고,생성된 마스크로 학습된 Mask-aware Autoencoder를 결합하였다. 이를 통해 사용자는 별도의 마스크나 이미지 프롬프트 없이 단일 텍스트 지시만으로 특정 객체를 정밀하

게 편집할 수 있으며, 얼굴 정체성을 보존하면서 제어 가능성, 다양성, 유연성을 동시에 달성하였다.

2.5. 통합 생성 벤치마크

기존의 FaceForensics++(FF++)이나 DFDC와 같은 딥페이크 데이터셋은 제한된 swapping 기법 및 reenactment 기법 등 특정 합성 방식에 편중되어 있어 새로운 합성 기술이 등장할 때마다 탐지 모델의 일반화 성능을 평가하기에는 한계가 있었다. 이러한 제약을 보완하기 위해 DF40[19]은 총 40종의 다양한 얼굴 합성 기법을 단일 벤치마크 내에 통합하여, 개별 기법 중심의 평가에서 벗어나 탐지 모델의 범용성과 일반화 능력을 체계적으로 검증할 수 있는 기반을 제공한다.

Ⅲ. 딥페이크 탐지 동향

3.1. Artifact 기반 탐지

Artifact 기반 탐지는 합성 과정에서 발생하는 저수준의 인공적 흔적을 탐지 단서로 활용하며, 딥페이크 탐지 연구의 초기부터 핵심적인 접근 방식으로 자리잡아 왔다. FaceForensics++[20]에서는 Xception 모델을 딥페이크 탐지에 처음 적용하여 이미지 전역의 특징을 단순히 분류하는 baseline을 제시하였고, 이후 F3-Net[21]은 DCT 변환을 통해 주파수 영역에서 나타나는 비정상적인 패턴을 포착하여 아티팩트 기반 탐지의 가능성을 확장하였다.

최근 연구는 아티팩트 기반 탐지를 고도화하여 실제 환경에서도 강건한 성능을 확보하는 방향으로 발전하고 있다. LSDA[22]는 distillation 기반 학습 구조를 도입하여 일반화된 딥페이크 탐지를 목표로 하였다. 먼저 teacher 모듈은 여러 합성 기법에서 나타나는 공통적 아티팩트를 학습하여 위조의 핵심 패턴을 포괄적으로 표현한다. 이어서 student 모듈은 teacher로부터 지식을 전달받아 학습함으로써, 실제 판별 과정에서 latent space 상의 고차원 표현을 이용해 위조 여부를 판정한다. 이러한 구조는 단순히 픽셀·주파수 단서에 의존하는 기존 탐지와 달리, 데이터셋과 합성 유형에 따라 달라질 수 있는 아티팩트를 보다 추상화된 표현으로 학습할 수 있게 한다.

ProFake[23]는 실제 환경에서 자주 발생하는 저품질 영상에서 탐지기가 성능을 잃는 문제를 해결하기 위해 제안되었다. 이를 위해 고해상도 영상을 입력받아 압축, 해상도 저하 등 다양한 수준의 열화 샘플을 생성하는 degradation generator를 두고, 탐지 모델이 품질과 위조 여부를 동시에 예측하도록 설계하였다. 학습 과정에서는 가장 심하게 열화된 샘플에서 시작해, 점차 덜 열화되거나 다양한 열화가 섞인 더 까다로운 조건으로 확대하는 curriculum 학습을 수행한다. 이를 통해 ProFake는 학습 초기에 뚜렷한 위조 단서를 익히고, 점차 다양한 열화 조건에도 적응하도록 훈련된다. 해당 모델은 FaceForensics++와 Celb-DF 데이터셋에 압축·해상도 저하 등 여러 열화 조건을 적용해 cross-quality 평가를 수행했으며, 그 결과 ProFake가 기존 탐지기에 비해 저품질 환경에서도 안정적으로 우수한 성능을 보였음을 확인하였다.

DiffusionFF[24]는 최신 diffusion 기반 합성 기법에 대응하기 위해 diffusion 모델의 고유한 노이즈 복원 메커니즘을 활용한 탐지 방식을 제안하였다. diffusion 모델은 노이즈를 점차 제거하며 이미지를 복원하는 과정을 거치는데, 합성 영상의 경우 이 과정에서 실제 영상과는 다른 잔여 노이즈가 남는다. DiffusionFF는 이러한 노이즈 분포를 역추적하여 합성 영상에서 발생하는 미세한 위조 흔적을 효과적으로 포착한다. 이를 위해 diffusion 과정의 중간 단계에서 샘플링된 노이즈 패턴을 특징으로 추출하고, 이를 판별기에 입력하여 위조 여부를 결정한다. 논문에서는 GAN, VAE, diffusion 계열을 포함한 다양한 합성 기법을 대상으로 평가를 진행했으며, DiffusionFF가 기존의 공간·주파수 기반 기존 탐지 모델보다 최신 diffusion 합성 영상에서 특히 우수한 성능을 보였음을 입증하였다.

3.2. Semantic 기반 탐지

Semantic 기반 탐지는 합성 영상의 정체성 일관성이나 시계열적 연속성과 같은 고수준 의미 단서를 활용하여 위조 여부를 판별한다. 합성 기술이 정교해지면서 단순 아티팩트 탐지만으로는 한계가 드러나 이후 얼굴의 구조적·시간적 불일치를 주요 단서로 삼았다. Yang 등[25]은 얼굴 랜드마크 기반으로 추정한 3D head pose의 불일치를 활용하였으며, Zheng 등[26]은 프레임 단위 합성에서 발생하는 시간적 불연속성을 포착하여 탐지 성능을 향상시켰다.

Semantic 기반 탐지의 최근 연구는 위조 의미를 보

다 정교하게 분리하고 학습하여 도메인 일반화 성능을 높이는 데 집중하고 있다. Ye 등 [27]은 위조 영상에서 나타나는 의미적 표현을 분리함으로써 일반화 성능을 강화하고자 하였다. 이를 위해 RGB 정보와 함께 Adaptive High-Pass Filtering을 적용하여 고주파 정보를 추출하고, 두 단계를 거쳐 forgery semantics와 non-forgery semantics를 분리한 뒤, forgery semantics를 다시 공통 위조 의미와 고유 위조 의미로 재구성하였다. 최종 판별에는 공통 위조 의미만을 활용하여 데이터셋 간 도메인 차이를 줄이고, 교차 데이터셋 환경에서 안정적인 성능을 확보하였다.

MoE-FFD[28]는 Transformer 기반 구조에 Mixture of Experts(MoE)를 결합한 효율적 탐지 모델을 제안하였다. 이 모델은 대규모 데이터셋으로 사전 학습된 Vision Transformer(ViT)의 백본 가중치는 동결한 상태로 둔 채 LoRA Layer와 Adapter Layer만 학습하여 파라미터 수를 크게 줄이면서도 새로운 도메인에 적응할 수 있도록 설계되었다. 특히 각 LoRA와 Adapter 모듈에는 MoE 구조가 포함되어 있어, 입력에 따라 서로 다른 전문가 모듈이 gating 네트워크를 통해 동적으로 선택된다. 이를 통해 불필요한 파라미터 업데이트 없이 위조 단서를 효과적으로 포착할 수 있었으며, 다양한 데이터셋과 조작 유형에서 교차 평가를 통해 기존 ViT 기반 모델 대비 향상된 AUC 성능을 입증하였다.

DiffusionFake[29]는 사전 학습된 diffusion 모델의 파라미터는 고정한 채, 탐지기가 추출한 특징을 diffusion 모델의 역과정에 주입하여 소스와 타깃 이미지를 각각 복원하도록 유도한다. 이 과정을 통해 탐지기는 입력된 합성 영상에서 정체성과 관련된 표현을 명확히 분리할 수 있게 되며, 위조와 무관한 요소와 위조 관련 요소가 혼재된 특징을 보다 구조적으로 학습하게 된다. 이러한 접근은 탐지기의 네트워크 구조나 파라미터를 추가로 변경하지 않으면서도 표현력을 개선할 수 있다는 장점이 있다. 실제로 EfficientNet-B4 기반 탐지기에 DiffusionFake를 결합했을 때, 추가적인 추론 비용 없이 교차 데이터셋 실험에서 기존 대비 크게 향상된 일반화 성능을 보였다.

3.3. 통합 탐지 벤치마크

딥페이크 탐지 기술의 발전을 객관적으로 검증하기 위해서는 다양한 데이터셋과 모델을 동일한 기준에서 비교할 수 있는 통합 검증 벤치마크가 필요하다. 기존 연구들은 각기 다른 데이터셋과 실험 설정을 사용해 성능을 보고함으로써, 모델 간 성능 비교나 일반화 능력 평가가 제한적이었다. 이러한 문제를 해결하기 위해 DeepfakeBench와 Deepfake-Eval-2024와 같은 통합 벤치마크가 제안되었다.

DeepfakeBench [30]는 여러 탐지 모델과 데이터셋을 통합하여 cross-dataset 환경에서 성능을 정량적으로 비교·평가할 수 있도록 설계되었다. 평가 지표로는 상위 3개 AUC 평균을 핵심으로 삼으며, AP (Average Precision), EER (Equal Error Rate), Precision, Recall과 같은 다양한 보조 지표를 함께 제공한다. 이를 통해 각 모델의 절대 성능뿐만 아니라, 도메인 변화에 따른 일반화 성능 차이까지 분석할 수 있다.

다음으로 Deepfake-Eval-2024[31]는 실제 소셜미디어 환경에서 수집된 데이터를 기반으로 구축된 최신 벤치마크이다. 기존 데이터셋이 상대적으로 정제된 합성 데이터를 포함한 것과 달리, 이 벤치마크는 업로드·다운로드·재인코딩 등 실제 유통 과정에서 발생하는 품질 열화 조건을 반영한다. 주요 지표로는 AUC, Precision, Recall, F1-score를 사용하며, 보조 지표로 Accuracy, FPR, FNR도 포함한다. 실험 결과, 기존 데이터셋에서 높은 성능을 보였던 탐지 모델들이 Deepfake-Eval-2024에서 성능이 크게 저하되었는데, 이러한 결과는 현재 탐지 모델들이 여전히 실제 환경에서의 일반화 성능에 취약함을 보여준다.

Ⅳ. 딥페이크 생성 및 탐지 기술의 한계와 과제

딥페이크 생성 기술은 GAN에서 diffusion 기반으로 발전하며 합성 영상의 사실성과 해상도가 크게 향상되었다. 그러나 이러한 발전은 탐지 기술의 취약성을 동시에 드러냈다. 초기 아티팩트 기반 탐지는 단순한 공간·주파수 흔적에 의존했으나, 최신 합성 기법에서는 이러한 단서가 점차 희미해지면서 기존 접근법만으로는 충분하지 않다. Semantic 기반 탐지 역시 정체성 일관성이나 시간적 연속성 등을 활용하여 성능을 개선했지만, 여전히 학습 데이터 특성에 의존하는 경향이 강해 도메인 전환 시 성능 저하가 나타난다.

탐지 연구의 또 다른 한계는 데이터와 학습 전략의 편중이다. 기존 데이터셋은 주로 정제된 환경에서 제작되어 실제 서비스 환경의 잡음, 압축, 해상도 저하와

〔표 1〕 최신 딥페이크 탐지 모델들의 학습 데이터셋, 평가 데이터셋, 인-도메인 및 교차 도메인 성능 비교.

Model		Vennue	Train Dataset	Test Dataset	In-Domain (AUC)	Cross-Domain (AUC)
Artifact	LSDA〔22〕	CVPR 2024	FF++_c23	CDF-v1/v2, DFD, DFDC, DFDCP	-	0.826
	ProFake〔23〕	CCS 2024	FF++, CDF, DFDC	FF++,CDF, DFDC	0.92(mid) 0.84(low)	-
	DiffusionFF〔24〕	arXive 2025	FF++	CDF-v2, DFDC, DFDCP, FFIW	0.99	0.90
Semantic	Ye et al.〔27〕	arXive 2024	FF++	FF++, CDF, DFD,DFDC	0.98	0.73
	MoE-FFD〔28〕	arXive 2024	FF++_c23	FF++, CDF, WDF, DFDC-P, DFD, DFR	0.98	0.86
	DiffusionFake〔29〕	NeurIPS 2024	FF++	CDF, WDF, DFDC-P, DFD, DiffSwap	-	0.83

는 괴리가 존재한다. 그 결과, [표 1]에서 탐지기는 인-도메인 환경에서는 0.9 이상의 높은 성능을 기록하지만, 도메인이 달라지면 성능이 급격히 떨어진다. 이는 탐지 모델이 여전히 일반화된 위조 특성을 포착하기보다는 특정 데이터셋의 통계적 특성에 과적합되어 있음을 보여준다. 따라서 향후 연구에서는 실제 환경과 유사한 조건을 반영한 데이터 수집, 품질 변화와 도메인 차이에 강건한 학습 전략이 필수적이다.

Ⅴ. 결 론

본 논문은 최근 딥페이크 생성과 탐지 기술의 발전 양상을 종합적으로 검토하였다. 생성은 GAN에서 diffusion 기반으로 전환되며 합성 품질과 사실성이 크게 향상되었고, 탐지는 아티팩트 기반에서 semantic 기반으로 진화했으나 여전히 일반화 취약성과 데이터 편중의 한계를 벗어나지 못하고 있다. 이러한 분석은 향후 연구가 단순한 성능 개선을 넘어, 실제 환경에서 안정적으로 동작할 수 있는 탐지 기술 확립으로 나아가야 함을 시사한다.

참 고 문 헌

[1] Korshunova, Iryna, et al., "Fast face-swap using convolutional neural networks." CVPR. 2017.

[2] Liu, Kunlin, et al., "Deepfacelab: Integrated, flexible and extensible face-swapping framework." Pattern Recognition 141. 2023

[3] Kim, Kihong, et al., "Diffface: Diffusion-based face swapping with facial guidance." Pattern Recognition 163 (2025): 111451.

[4] Baliah, Sanoojan, et al., "Realistic and efficient face swapping: A unified approach with diffusion models." WACV, 2025.

[5] Ye, Fulong, et al., "DreamID: High-Fidelity and Fast diffusion-based Face Swapping via Triplet ID Group Learning." arXiv. 2025.

[6] Nirkin, Yuval, Yosi Keller, and Tal Hassner. "Fsgan: Subject agnostic face swapping and reenactment." CVPR. 2019.

[7] Zhao, Jian, and Hui Zhang. "Thin-plate spline motion model for image animation." CVPR. 2022.

[8] Zhang, Wenxuan, et al., "Sadtalker: Learning realistic 3d motion coefficients for stylized audio-driven single image talking face animation." CVPR 2023.

[9] Bounareli, Stella, et al., "Hyperreenact: one-shot reenactment via jointly learning to refine and retarget faces." ICCV. 2023.

[10] Bounareli, Stella, et al., "Diffusionact: Controllable diffusion autoencoder for one-shot face reenactment." FG. IEEE, 2025.

[11] Sauer, Axel, Katja Schwarz, and Andreas Geiger."Stylegan-xl: Scaling stylegan to large diverse datasets." ACM SIGGRAPH.2022.

[12] Chen, Junsong, et al., "Pixart-α: Fast training of diffusion transformer for photorealistic text-to-image synthesis." arXiv. 2023.
[13] Chen, Junsong, et al., "Pixart-σ: Weak-to-strong training of diffusion transformer for 4k text-to-image generation." ECCV, 2024.
[14] Tomašević, Darian, et al., "ID-Booth: Identity-consistent Face Generation with Diffusion Models." arXiv preprint arXiv,2025.
[15] Choi, Yunjey, et al.," Stargan: Unified generative adversarial networks for multi-domain image-to-image translation." CVPR. 2018.
[16] Huang, Ziqi, et al., "Collaborative diffusion for multi-modal face generation and editing." CVPR. 2023.
[17] Mou, Chong, et al., "Diffeditor: Boosting accuracy and flexibility on diffusion-based image editing." CVPR. 2024.
[18] Zhang, Xin, et al., "MuseFace: Text-driven Face Editing via Diffusion-based Mask Generation Approach." arXiv. 2025.
[19] Yan, Zhiyuan, et al., "Df40: Toward next-generation deepfake detection." NeurIPS.2024.
[20] Rossler, Andreas, et al., "Faceforensics++: Learning to detect manipulated facial images." CVPR. 2019.
[21] Wei, Jun, Shuhui Wang, and Qingming Huang. "F^3Net: fusion, feedback and focus for salient object detection." AAAI. 2020.
[22] Yan, Zhiyuan, et al., "Transcending forgery specificity with latent space augmentation for generalizable deepfake detection." CVPR. 2024.
[23] Xu, Huiyu, et al., “ProFake: Detecting Deepfakes in the Wild against Quality Degradation with Progressive Quality-adaptive Learning.” ACM CCS. 2024.
[24] Peng, Siran, et al., "DiffusionFF: Face Forgery Detection via Diffusion-based Artifact Localization." arXiv. 2025.
[25] Yang, Xin, Yuezun Li, and Siwei Lyu. "Exposing deep fakes using inconsistent head poses." ICASSP. IEEE, 2019.
[26] Zheng, Yinglin, et al., "Exploring temporal coherence for more general video face forgery detection." CVPR. 2021.
[27] Ye, Wei, Xinan He, and Feng Ding. "Decoupling forgery semantics for generalizable deepfake detection." arXiv.2024.
[28] Kong, Chenqi, et al., "Moe-ffd: Mixture of experts for generalized and parameter-efficient face forgery detection." arXiv. 2024.
[29] Chen, Shen, et al., "Diffusionfake: Enhancing generalization in deepfake detection via guided stable diffusion." NeurIPS. 2024.
[30] Yan, Zhiyuan, et al., "DeepfakeBench: A Comprehensive Benchmark of Deepfake Detection." NeurIPS. 2023.
[31] Chandra, Nuria Alina, et al., "Deepfake-eval-2024: A multi-modal in-the-wild benchmark of deepfakes circulated in 2024." arXiv. 2025.

〈 저 자 소 개 〉

황 은 비 (Eunbi Hwang)
2019년 2월 : 성신여자대학교 통계학과 졸업
2019년 9월~현재 : 연세대학교 정보대학원 정보보호트랙 석·박사 통합과정
<관심분야> 정보보안, 딥페이크 탐지, 사용자 인증

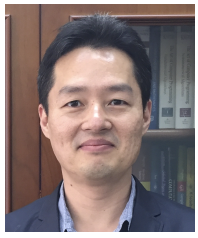

권 태 경 (Taekyoung Kwon)
종신회원
1992년 2월 : 연세대학교 컴퓨터과학과 졸업
1995년 2월 : 연세대학교 컴퓨터과학과 석사
1999년 8월 : 연세대학교 컴퓨터과학과 박사
1999년~2000년 : 미국 캘리포니아대학교 버클리 캠퍼스 박사후 연구원
2001년~2013년 : 세종대학교 컴퓨터공학과 교수
2013년~현재 : 연세대학교 정보대학원 교수
<관심분야> AI 보안, 시스템 보안, 인증, 정보보호