https://doi.org/10.5392/JKCA.2026.26.01.001

실시간 딥페이크 영상 탐지를 위한 MobileNet과 Bi-LSTM 모델을 활용한 경량화 모델

Lightweight Deepfake Video Detection Using MobileNet and Bi-LSTM for Real-Time Applications

황현국, 곽내정, 이병엽
배재대학교 정보보안학과

Hyeon-Guk Hwang(ahddl321@gmail.com), Nae-Jeong Kwak(knj0125@pcu.ac.kr),
Byung-Yeop Lee(bylee@pcu.ac.kr)

요약

딥페이크 영상은 인물의 얼굴을 AI로 합성하는 기술로, 온라인 정보의 신뢰성을 위협하는 사회적 문제로 부각되고 있다. 본 연구는 모바일·엣지 환경에서 활용 가능한 두 가지 경량 탐지 모델을 제안한다. MobileNetV2+Bi-LSTM은 경량성과 실시간성에 중점을 두었고, MobileNetV3+Bi-LSTM은 정확도 향상을 목표로 한다. 두 모델은 CNN 기반 시각적 특징과 Bi-LSTM 기반 시간적 일관성을 동시에 학습하며, Celeb-DF v2 데이터셋과 'Golden Frame' 전처리, AMP 최적화를 적용하였다. 실험 결과, MobileNetV2+Bi-LSTM은 정확도 96.64%, F1-score 0.9812, AUC 0.9631을 달성했으며, MobileNetV3+Bi-LSTM은 정확도 97.27%, F1-score 0.9842, AUC 0.9937로 더 높은 탐지 성능을 보였다.

■ 중심어 : | 딥러닝 | 딥페이크 탐지 | MobileNet | Bi-LSTM |

Abstract

Deepfake videos, which synthesize human faces using AI, have emerged as a social issue that threatens the reliability of online information. This study proposes two lightweight detection models applicable to mobile and edge environments. MobileNetV2+Bi-LSTM focuses on efficiency and real-time performance, while MobileNetV3+Bi-LSTM aims for higher accuracy. Both models jointly learn visual features via CNNs and temporal consistency via Bi-LSTMs, employing the Celeb-DF v2 dataset, "Golden Frame" preprocessing, and AMP-based optimization. Experimental results show that MobileNetV2+Bi-LSTM achieved 96.64% accuracy, 0.9812 F1-score, and 0.9631 AUC, whereas MobileNetV3+Bi-LSTM recorded 97.27% accuracy, 0.9842 F1-score, and 0.9937 AUC, demonstrating superior detection performance.

■ keyword : | Deep Learning | Deepfake Detection | MobileNet | Bi-LSTM |

* 이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원-지역지능화혁신인재양성사업의 지원(IITP-2026-RS-2022-00156334, 50%)과, 교육부와 한국연구재단의 재원으로 첨단분야 혁신융합대학사업의 지원을 받아 수행된 연구임(50%)
접수일자 : 2025년 10월 14일
수정일자 : 2025년 11월 04일
심사완료일 : 2025년 11월 04일
교신저자 : 이병엽, e-mail : bylee@pcu.ac.kr

I. 서론

딥페이크(Deepfake)는 인물의 얼굴을 다른 사람의 얼굴로 교체하거나 음성을 합성하는 기술로, 최근 빠르게 확산되고 있다. 고성능 그래픽 처리 장치(GPU)와 공개 소스 코드의 보급으로 일반 사용자도 손쉽게 고품질 딥페이크를 제작할 수 있게 되면서, 가짜 뉴스, 명예 훼손, 개인정보 침해 등 심각한 사회적 문제가 대두되고 있다. 이러한 위협은 온라인 콘텐츠에 대한 신뢰도를 저하시킬 뿐만 아니라 법적 규제의 필요성까지 제기하고 있다. 기존의 딥페이크 탐지 연구들은 주로 합성곱 신경망(CNN)을 활용한 프레임 단위 분석에 집중해 왔다[1]. 예를 들어, XceptionNet[2]이나 EfficientNet[3]과 같은 대용량 모델은 높은 정확도를 달성하였으나, 연산량이 많아 실시간 처리나 엣지 환경에는 적합하지 않다. 또한 CNN 기반 모델은 영상 내 시간적 패턴을 충분히 반영하지 못하여 연속된 프레임에서 발생하는 미세한 변화를 효과적으로 포착하기 어렵다[4]. 이를 보완하기 위해 RNN이나 LSTM 기반 탐지 기법이 제안되었으나, 이들 역시 모델 규모가 크고 추론 속도가 느리며, 대부분 과거 정보만 활용하는 단방향 구조의 한계를 지닌다[5].

본 논문은 이러한 한계를 극복하기 위해 경량 딥페이크 탐지 모델을 설계한다. 이를 위해 MobileNetv2[6]와 MobileNetv3[7]의 깊이별 분리 합성곱과 선형 병목 구조를 적용하여 파라미터 수와 연산량을 줄이고, Bi-LSTM[8]을 결합하여 프레임 시퀀스를 양방향으로 처리함으로써 시간적 일관성과 맥락 정보를 동시에 반영한다. 제안된 모델은 정확도, 파라미터 수, 연산 효율 등의 지표를 기반으로 기존 모델과 성능을 정량적으로 비교하며, 모바일 및 엣지 환경에서 효율적으로 딥페이크를 탐지할 수 있는 방안을 제시한다.

본 논문의 구성은 다음과 같다. 2장에서는 딥페이크 탐지와 관련된 기존 관련 연구들을 소개하며 MobileNet, Bi-LSTM 및 Golden Frame 기법의 특징을 설명한다. 3장에서는 제안하는 경량 딥페이크 탐지 모델과 입력 데이터의 전처리 과정을 설명한다. 4장에서는 제안모델의 성능을 평가하기 위한 실험 환경과 성능을 분석하며 마지막으로 5장에서는 연구의 결론과 한계점을 정리하고, 향후 연구 방향을 제시한다.

II. 기존 관련 연구

1. MobileNet

딥페이크 탐지 분야에서 합성곱 신경망(CNN)은 이미지 수준의 특징을 추출하는 기본 도구로 널리 활용된다. 예를 들어 XceptionNet과 VGG16[9]은 깊은 네트워크 층과 대규모 파라미터를 기반으로 높은 성능을 보였으나, 그로 인해 경량성이 낮다는 한계를 가진다. MobileNetV2는 모바일 장치를 위해 설계된 경량 CNN 아키텍처로, 깊이별 분리 합성곱(depthwise separable convolution)을 도입하여 표준 합성곱 연산을 채널별 필터링과 1×1 포인트 합성곱으로 분리함으로써 연산량을 크게 감소시킨다. 또한 역잔차(inverted residual) 구조와 선형 병목(linear bottleneck)을 적용하여 입력 채널을 먼저 확장한 후 깊이별 합성곱을 수행하고 다시 축소하는 과정을 통해 정보 손실을 최소화한다. [그림 1]은 MobileNetV2의 Residual block과 Inverted residual block의 구성도이다.

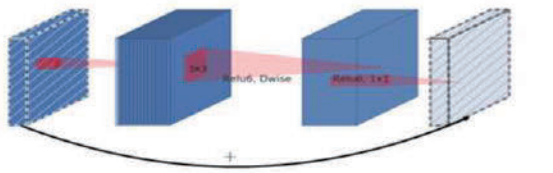

(a): Residual block

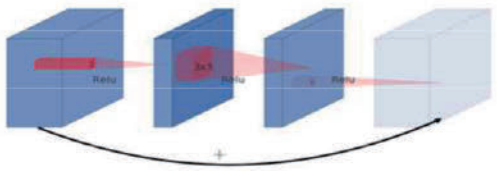

(b): Inverted residual block

그림 1. MobileNetV2의 Residual block과 Inverted residual block의 구성도

2. RNN과 Bi-LSTM

순환 신경망(RNN)은 시퀀스 데이터를 처리하는 데 널리 활용되며, 장기 의존성 문제를 개선하기 위해 다양한 변형 모델이 제안되었다. 그중 장단기 메모리 네트워크(LSTM)는 게이트 구조를 통해 장기적인 의존 관

계를 효과적으로 학습할 수 있다. 그러나 단방향 LSTM은 과거 정보에만 의존하기 때문에 시간적 패턴을 완전하게 반영하기 어렵다는 한계를 가진다. 이를 보완하기 위해 제안된 양방향 RNN(Bi-RNN)은 동일한 입력 시퀀스를 정방향과 역방향으로 각각 처리한 뒤 출력을 결합함으로써 과거와 미래의 정보를 동시에 활용한다. 이러한 구조를 LSTM에 적용한 양방향 LSTM(Bi-LSTM)은 시계열 특성을 고려하는 다양한 응용 분야에서 우수한 성능을 보여 왔다. [그림 2]는 Bi-LSTM의 구성도이다.

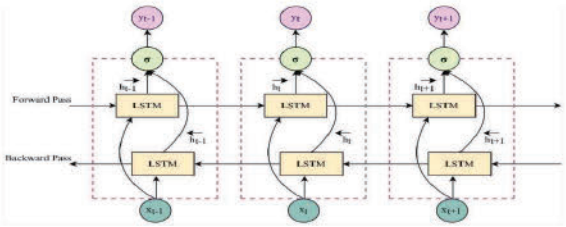

그림 2. Bi-LSTM[10]

3. Golden Frame

최근 영상 기반 분류 연구에서는 모든 프레임을 처리하는 대신, 중요한 정보를 포함하는 핵심 프레임만 선택하여 효율성을 높이는 기법이 주목받고 있다. Golden Frame 방식은 입력된 비디오 스트림을 일정 간격으로 샘플링한 후, 인접 프레임 간 밝기 차이를 계산하여 모션 변화가 큰 상위 K개의 프레임을 Golden Frame으로 선택한다. 이 방법은 전체 프레임을 처리하지 않고도 움직임이 두드러진 구간을 선별할 수 있어 효율적이고 신속한 전처리를 가능하게 하며, 동시에 잡음을 제거하는 데 효과적이다. 최근 연구[11]에서도 이러한 Golden Frame 추출 기법을 딥페이크 탐지에 적용하여, 전체 프레임의 일부만 사용하더라도 분류 성능을 유지하면서 학습 및 추론 속도를 향상시킬 수 있음을 확인하였다.

Ⅲ. 본론

본 연구에서는 모바일 및 엣지 환경에서 활용 가능한 두 가지 경량 딥페이크 탐지 모델을 제안한다. 첫 번째 모델은 경량성과 실시간성에 중점을 두었으며, 공간적 특성을 학습하기 위해 경량 CNN 모델인 MobileNetV2를 사용하고, 시간적 특성을 학습하기 위해 Bi-LSTM을 결합하였다. 두 번째 모델은 딥페이크 판별 정확도를 높이기 위해 MobileNetV2를 개선한 MobileNetV3와 Bi-LSTM을 결합하였다.

제안하는 모델은 입력된 비디오 스트림을 Golden Frame 방식으로 전처리하여 잡음을 제거하고, 특징 추출에 적합한 후보 프레임을 선택한다. 선택된 각 Golden Frame에 대해서는 MTCNN[12]을 적용하여 얼굴 영역을 검출한 뒤, 이를 224×224 크기로 크롭(crop) 및 정규화(normalization)한다. MTCNN은 다양한 조명 조건과 얼굴 각도에서도 안정적인 성능을 보이는 다단계 얼굴 검출기로, 모델 입력에 필요한 고품질 얼굴 이미지를 확보하는 데 활용된다.

MTCNN의 출력으로 얻은 얼굴 이미지는 MobileNetV2와 MobileNetV3 백본(backbone)에 입력되어 공간적 특징을 추출한다. 본 연구에서 활용한 MobileNetV2와 MobileNetV3는 사전 학습된(pretrained) 모델로, 계산 복잡도와 파라미터 수를 크게 줄이면서도 충분한 표현력을 유지할 수 있다는 장점을 지닌다. 이후 Adaptive Average Pooling을 적용하여 프레임별 특징 벡터를

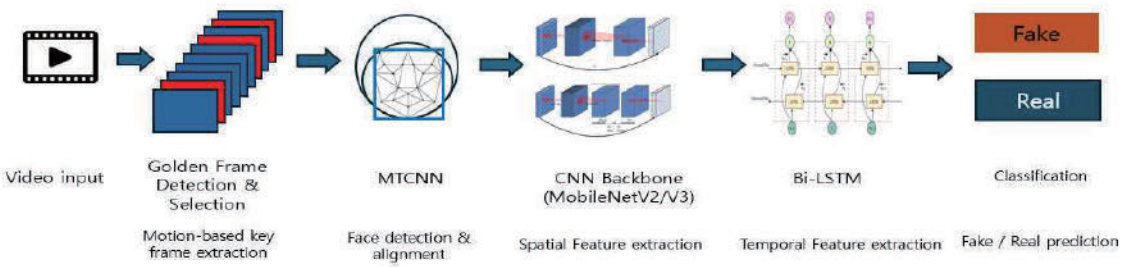

그림 3. 제안 방법의 시스템 구성도

정제하며, 이 시퀀스는 Bi-LSTM의 입력으로 전달되어 시간적 상관관계를 학습한다. Bi-LSTM은 256개의 은닉 유닛으로 구성되어 있으며, 과거와 미래의 맥락 정보를 동시에 반영하여 풍부한 시계열 특징을 학습한다.

마지막으로 Bi-LSTM의 출력은 평균 풀링을 거쳐 분류기에 전달되며, 이를 통해 입력 영상이 실제(real)인지 혹은 딥페이크(fake)인지 최종 판별한다. [그림 3]은 본 연구에서 제안하는 전체 시스템의 구성도이다.

Ⅳ. 실험 및 결과

1. 데이터셋

본 연구에서는 딥페이크 영상 탐지 성능을 평가하기 위해 CelebDF-v2 데이터셋을 사용하였다. CelebDF-v2는 Li 등[13]이 제안한 고품질 딥페이크 영상 데이터셋으로, 총 6,229개의 영상으로 구성되어 있으며, 이 중 590개는 실제(real) 영상이고 5,639개는 딥페이크(fake) 영상이다. 딥페이크 영상은 Celeb-real 영상을 기반으로 생성되었으며, 자연스러운 얼굴 움직임을 갖는 852×480 해상도의 고품질 영상으로 제공된다. 해당 데이터셋은 기존 딥페이크 데이터셋에 비해 시각적 품질이 높고 인위적인 왜곡이 적어, 탐지 난이도가 상대적으로 높다는 특징을 가진다.

그림 4. Celeb-DF v2 데이터셋 이미지

본 연구에서는 CelebDF-v2의 전체 영상으로부터 프레임을 추출하여 전처리를 수행한 뒤, 이를 분류 모델의 입력으로 사용하였다. 성능 평가는 전체 데이터를 학습용 80%, 검증용 10%, 테스트용 10%로 분할하여 진행하였으며, 모든 결과는 테스트 데이터를 기준으로 보고하였다. CelebDF-v2는 852×480 크기의 고해상도 영상으로, 기존 딥페이크 데이터셋에 비해 시각적 품질이 높고, 인위적인 왜곡이 적어 탐지 난이도가 상대적으로 높다.

2. 실험 환경

본 논문에서 사용한 환경은 다음과 같다:

OS	Windows 11
GPU	NVIDIA GeForce RTX 3080 12GB
CPU	12th Gen Intel(R) Core(TM) i5-12600K 3.69 GHz
RAM	64GB
CUDA	11.8
cuDNN	8.7.0
software	python 3.10/pytorch2.1.2

모델 학습 과정에서 배치 크기(batch size)는 8로 설정하였으며, 손실 함수는 CrossEntropy를 사용하였다. 학습률(learning rate)은 0.001로 초기화하였고, 총 25 epoch 동안 학습을 수행하였다. 또한 검증 손실(validation loss)이 5 epoch 이상 개선되지 않을 경우 조기 종료(Early Stopping) 기법을 적용하여 과적합을 방지하였다. 더불어 GPU 메모리 사용을 줄이고 학습 및 추론 효율을 향상시키기 위해 AMP(Automatic Mixed Precision) 기법을 적용하였으며, 이를 통해 FP16 기반의 혼합 정밀도 연산을 수행하였다.

3. 실험 결과

본 연구에서는 모델 성능 평가를 위해 정확도(Accuracy), F1-score, AUC, 파라미터 수를 주요 지표로 사용하였다. 성능 평가는 두 단계로 진행되었다.

(1) 제안 모델(MobileNetV2 + Bi-LSTM, MobileNe-tV3 + Bi-LSTM)과 기존 모델(EfficientNetV2-B0, Mobi leNetV2, MobileNetV3)의 성능 비교

(2) MobileNetV2 + Bi-LSTM과 MobileNetV3 + Bi-LSTM 간 성능 비교 및 분석

3.1 제안 모델과 기존 모델의 성능 평가

제안한 MobileNetV2 + Bi-LSTM 및 MobileNetV3 + Bi-LSTM 모델의 성능을 기존 모델과 비교하기 위해, 입력 비디오에서 Golden Frame 추출 기법을 적용하여 일정한 프레임을 선택하였다.

Golden Frame은 입력된 비디오 스트림을 5프레임 간격으로 샘플링한 후, 인접 프레임 간 밝기 변화를 계산하여 모션 변화가 큰 상위 K개의 프레임을 선택하는 방식으로 구성된다. 이때 K값은 입력 시퀀스 길이에 따라 저속 환경(5프레임 입력)과 고속 환경(25프레임 입력)으로 구분하여 설정하였다. 즉, 저속 실험에서는 상대적으로 적은 프레임을 사용해 연산 효율성을 평가하였고, 고속 실험에서는 풍부한 시간 정보를 반영하여 성능 변화를 분석하였으며동일 분할·동일 설정에서 무작위 초기화에 따른 지표 변동은 통상 ±0.2-0.8%p 수준으로 보고된다. 결과는 [표 1]과 [표 2]에 제시하였다.

표 1. 5프레임 실험 결과

모델	Acc	F1-Score	AUC	파라미터 수
EfficientNetV2-B0	0.9343	0.9544	0.9239	7,142,266
MobileNetV2	0.9358	0.9628	0.9547	2,226,434
MobileNetV3	0.9144	0.9492	0.9492	2,973,874
EfficientNetV2-B0+Bi-LSTM	0.9205	0.9544	0.9138	10,290,554
MobileNetV2 + Bi-LSTM	0.9358	0.9642	0.9367	5,374,722
MobileNetV3 + Bi-LSTM	0.9343	0.9623	0.9444	7,978,522

표 2. 25프레임 실험 결과

모델	Acc	F1-Score	AUC	파라미터 수
EfficientNetV2-B0	0.9541	0.9737	0.9800	7,142,266
MobileNetV2	0.9434	0.9674	0.9733	2,226,434
MobileNetV3	0.9450	0.9690	0.9734	2,973,874
EfficientNetV2-B0+Bi-LSTM	0.9648	0.9803	0.9829	10,290,554
MobileNetV2 + Bi-LSTM	0.9664	0.9812	0.9631	5,374,722
MobileNetV3 + Bi-LSTM	0.9648	0.9797	0.9905	7,978,522

[표 1]과 [표 2]의 결과에 따르면, 25프레임을 입력으로 한 경우가 5프레임 입력 대비 전반적으로 더 우수한 성능을 보였다. 이는 입력 프레임 수가 많을수록 시간적 정보를 풍부하게 반영할 수 있어 모델 성능이 향상됨을 의미한다.

EfficientNetV2-B0 모델은 Bi-LSTM을 결합하지 않은 경우 정확도에서 가장 높은 성능을 보였으나, F1-score와 AUC 지표에서는 Bi-LSTM을 결합한 모델들이 더 나은 결과를 기록하였다. 특히 MobileNetV2와 MobileNetV3는 Bi-LSTM 결합 시 정확도, F1-score, AUC 모든 지표에서 개선된 성능을 나타내어, Bi-LSTM이 입력 데이터의 시간적 패턴 학습에 효과적임을 보여주었다.

세부적으로, MobileNetV2 + Bi-LSTM은 5프레임 및 25프레임 입력 모두에서 정확도(0.9358 / 0.9664)와 F1-score(0.9642 / 0.9812)에서 가장 우수한 성능을 보였다. 반면, AUC는 MobileNetV3 + Bi-LSTM이 각각 0.9444와 0.9905로 가장 높은 성능을 달성하였다. 이러한 결과는 충분한 입력 프레임이 제공될 경우 Bi-LSTM이 시간적 패턴을 효과적으로 학습하여 성능을 향상시킬 수 있으며, 경량 모델과의 결합이 실시간 환경에서도 효율적임을 보인다.

3.2 제안 모델의 성능 분석

본 연구에서는 MobileNetV2 + Bi-LSTM과 MobileNetV3 + Bi-LSTM 모델의 성능 변화를 보다 정밀하게 검증하기 위해 Golden Frame의 선택 개수(K) 를 5, 10, 20, 25로 변화시키며 성능을 평가하였다. Golden Frame은 입력된 비디오 스트림을 5프레임 간격으로 샘플링한 후, 인접 프레임 간 밝기 차이를 계산하여 모션 변화가 큰 상위 K개의 프레임을 선택하는 방식으로 구성되었다. 이렇게 선택된 프레임 수(K)는 곧 입력 시퀀스 길이를 의미하며, 시간적 정보의 풍부함이 모델의 성능에 어떤 영향을 미치는지를 분석하였다. [표 3]은 프레임 수에 따른 모델별 성능 평가 결과를 제시한다.

MobileNetV3 + Bi-LSTM은 20프레임 입력에서 정확도 0.9726, F1-score 0.9842, AUC 0.9937로 최고 성능을 보였다. 그러나 25프레임에서는 세 지표 모두에서 소폭 성능 저하가 발생하였다. MobileNetV2 + Bi-LSTM은 25프레임 입력에서 정확도 0.9664, F1-score 0.9812, AUC 0.9631로 가장 우수한 성능을 보였으나, 10프레임 입력에서는 일시적인 성능 저하가 관찰되었다. 이 결과는 입력 프레임 수(K값)가 모델의 시간적 특징 학습에 직접적인 영향을 미치며, 일정 수준 이상에서는 과도한 프레임 입력이 오히려 일반화 성능을 저하시킬 수 있음을 보여준다.

또한, MobileNetV2 + Bi-LSTM은 파라미터 수가 5.37M으로 상대적으로 경량성을 유지하면서도 정확도 0.9664, F1-score 0.9812를 달성하여 실시간 환경에

적합한 성능을 보였다. 반면, MobileNetV3 + Bi-LSTM은 7.98M의 파라미터를 사용하였으나 더 높은 탐지 성능을 달성하였다. 두 모델 모두 정확도와 효율성 측면에서 우수한 균형을 보이며, 특히 모바일 및 엣지 디바이스와 같은 제한된 연산 환경에서 활용 가능성이 높다. 따라서 정확도가 중요한 응용에는 MobileNetV3 + Bi-LSTM 모델이, 경량성이 중요한 응용에는 MobileNetV2 + Bi-LSTM 모델이 적합할 것으로 판단된다.

표 3. 프레임 수에 따른 Bi-LSTM 모델별 성능 비교

프레임 수	모델	Acc	F1-Score	AUC
5프레임	MobileNetV2 + Bi-LSTM	0.9358	0.9642	0.9367
	MobileNetV3 + Bi-LSTM	0.9343	0.9623	0.9444
10프레임	MobileNetV2 + Bi-LSTM	0.9190	0.9536	0.9362
	MobileNetV3 + Bi-LSTM	0.9526	0.9719	0.9797
20프레임	MobileNetV2 + Bi-LSTM	0.9419	0.9671	0.9588
	MobileNetV3 + Bi-LSTM	0.9726	0.9842	0.9937
25프레임	MobileNetV2 + Bi-LSTM	0.9664	0.9812	0.9631
	MobileNetV3 + Bi-LSTM	0.9648	0.9797	0.9905

표 4. 모델에 대한 자세한 성능 지표

모델	Precision	Recall	Loss	FPS	파라미터 수
MobileNetV2 + Bi-LSTM (25 프레임)	0.9696	0.9931	0.1095	1140.59	5,374,722
MobileNetV3 + Bi-LSTM (20 프레임)	0.9808	0.9877	0.0718	1154.71	7,978,522

[표 4]는 각 모델의 최고 성능 설정에서 Precision, Recall, Loss, FPS, 파라미터 수를 비교한 결과이다. 동일 모델·동일 프레임 수 조건에서 Golden Frame 적용은 정확도(+3.67%p), F1(+2.21%p), AUC(+1.35%p)를 모두 향상시켰으며, 이는 Golden Frame 기법이 모션 변화가 큰 핵심 프레임을 선별해 저정보 프레임을 걸러냄으로써 성능 향상에 연관이 있음을 보여준다.

V. 결론 및 향후 과제

본 논문에서는 Golden Frame 기반 프레임 선택 기법과 MobileNet + Bi-LSTM 구조를 결합한 경량 딥페이크 영상 탐지 모델을 제안하였다. 전처리를 위한 Golden Frame 방식은 전체 영상 대비 모션 변화가 큰 프레임만을 선택하여 연산량을 줄이면서도 의미 있는 정보를 효과적으로 보존하였다.

MobileNetV2와 MobileNetV3는 깊이별 분리 합성곱과 역잔차 구조를 통해 계산 복잡도를 줄이면서도 충분한 표현력을 유지하였으며, Bi-LSTM은 시퀀스를 양방향으로 처리하여 시간적 일관성을 반영함으로써 탐지 성능을 향상시켰다. 이를 통해 제안 모델은 모바일 및 엣지 환경에서도 실시간 처리가 가능한 경량성과 실용성을 입증하였다.

CelebDF-v2 데이터셋 기반의 실험 결과, MobileNet V2 + Bi-LSTM 모델은 정확도 0.9664, F1-score 0.9812, AUC 0.9631을 달성하여 MobileNetV3 + Bi-LSTM에 비해 성능은 다소 낮지만, 더 적은 파라미터 수를 사용하여 경량성과 성능 간의 균형을 잘 유지하였다. 반면 MobileNetV3 + Bi-LSTM 모델은 정확도 0.9726, F1-score 0.9842, AUC 0.9937을 기록하여 파라미터 수는 더 크지만 여전히 경량 모델로 활용 가능한 수준을 유지하면서 가장 우수한 탐지 성능을 보였다.

향후 연구에서는 Golden Frame 비교 과정에서 나타난 학습 편차를 완화하고, 프레임 선택 기준을 정교화하거나 학습 기반 메커니즘을 도입해 프레임 중요도를 자동 결정하는 방안을 모색할 것이다. 또한 본 연구는 경량화 설계에 초점을 두었으므로 실제 임베디드 환경에서의 성능 검증은 수행하지 않았다. 앞으로는 임베디드·엣지 디바이스에서의 추론 속도, FPS, 전력 소모 등을 계량적으로 측정해 제안 모델의 실효성과 실시간성에 대한 평가를 구체화할 예정이다. 또한 본 연구에서 확인한 경량성과 성능 지표는 실시간 딥페이크 탐지로의 적용 가능성을 시사하며, 이는 허위정보 확산 억제·프라이버시 보호 등 사회적 측면과 콘텐츠 모더레이션 지원·운영 효율 제고 등 산업적 측면에서의 활용 잠재력을 갖는다. 최종적으로, 모바일·엣지 디바이스 상에

서의 실증을 통해 제안 모델을 실용적 딥페이크 방지 솔루션으로 확장할 수 있을 것으로 기대한다.

참 고 문 헌

[1] V. L. L. Thing, "Deepfake Detection with Deep Learning: Convolutional Neural Networks versus Transformers," arXiv preprint, arXiv:2304.03698, 2023.

[2] F. Chollet, "Xception: Deep learning with depthwise separable convolutions," in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), pp.1251-1258, 2017.

[3] M. Tan and Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in Proc. 36th Int. Conf. Machine Learning (ICML), 2019, pp. 6105-6114.

[4] D. Wodajo and S. Atnafu, "Deepfake detection using convolutional vision transformers," Soft Computing, Vol.28, 2024.
[Online] Available: https://link.springer.com/article/10.1007/s00521-024-10181-7

[5] P. Saikia, D. Dholaria, P. Yadav, V. Patel, and M. Roy, "A hybrid CNN-LSTM model for video deepfake detection by leveraging optical flow features," arXiv preprint, arXiv:2208.00788, 2022.

[6] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L. C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), pp.4510-4520, 2018.

[7] A. Howard, M. Sandler, G. Chu, L. C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. Le, and H. Adam, "Searching for MobileNetV3," in Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV), pp.1314-1324, 2019.

[8] A. Graves and J. Schmidhuber, "Framewise phoneme classification with bidirectional LSTM and other neural network architectures," Neural Networks, Vol.18, No.5-6, pp.602-610, 2005.

[9] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," arXiv preprint, arXiv:1409.1556, 2014.

[10] D. Naik and C. D. Jaidhar, "A novel Multi-Layer Attention Framework for visual description prediction using bidirectional LSTM," Journal of Big Data, Vol.9, 2022(11).

[11] K. Lipianina-Honcharenko, N. Melnyk, A. Ivasechko, M. Telka, and O. Illiashenko, "Neural network ensemble method for deepfake classification using golden frame selection," Big Data and Cognitive Computing, Vol.9, No.4, 2023.
[Online] Available: https://www.mdpi.com/2504-2289/9/4/109

[12] K. Zhang, Z. Zhang, Z. Li, and Y. Qiao, "Joint face detection and alignment using multitask cascaded convolutional networks," IEEE Signal Processing Letters, Vol.23, No.10, pp.1499-1503, 2016.

[13] Y. Li, X. Yang, P. Sun, H. Qi, and S. Lyu, "Celeb-DF: A large-scale challenging dataset for deepfake forensics," in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), pp.3207-3216, 2020.

저 자 소 개

황 현 국(Hyeon-Guk Hwang) 준회원

▪ 2020년 3월 ~ 현재 : 배재대학교 정보보안학과 학부생

〈관심분야〉 : 멀티미디어신호처리, 객체인식, 정보보안, 빅데이터 처리, 기계학습 및 딥러닝

곽 내 정(Nae-Joung Kwak) **종신회원**

- 1993년 2월 : 충북대학교 정보통신공학과(공학사)
- 1995년 2월 : 충북대학교 정보통신공학과(공학석사)
- 2005년 2월 : 충북대학교 정보통신공학과(공학박석사)
- 2006년 3월 ~ 2009년 2월 : 목원대학교 전임강사
- 2009년 3월 ~ 2020년 3월 : 충북대학교 시간강사
- 2020년 3월 ~ 현재 : 배재대학교 정보보안학과 교수

〈관심분야〉 : 상황인지, 멀티미디어신호처리, 객체인식, 정보보안, 빅데이터 처리, 기계학습 및 딥러닝

이 병 엽(Byoung-Yup Lee) **종신회원**

- 1991년 2월 : 한국과학기술원 전산학과(공학사)
- 1993년 2월 : 한국과학기술원 전산학과(공학석사)
- 1997년 2월 : 한국과학기술원 경영정보공학(공학박사)
- 1993년 1월 ~ 2003년 2월 : 대우정보시스템 차장
- 2003년 3월 ~ 현재 : 배재대학교 정보보안학과 교수

〈관심분야〉 : 정보보안, 지능정보시스템, 데이터베이스시스템, 인공지능