영상 위변조 방지를 위한 생성 AI 이미지 판별 기법

송창우*, 박화종, 장다혜, 채선혜
㈜인텍플러스

{*cwsong, hjpark, dhjang, shshw0417} @ intekplus.com

Image Classification for result from Generative AI to prevent image forgery

Chang Woo Song*, Hwa-Jong Park, DaHye Jang, Seonhye Chae
IntekPlus Co, Ltd.

요 약

본 논문은 악의적인 목적의 영상 위변조를 방지하기 위한 생성 AI 이미지를 판별하는 기법을 제안한다. 제안하는 네트워크는 생성된 이미지와 실제 이미지를 구분하기 위해 Efficient Net을 사용함과 동시에 Auto Encoder를 통해 복원된 이미지를 제안하는 손실(loss) 함수를 통해 학습한다. 객관적인 성능 평가를 위해, 관련 경진대회 데이터셋을 활용하여 리더보드를 통해 확인한 F1 Score는 0.9023을 얻었다.

Ⅰ. 서 론

최근 생성 모델의 큰 발전으로 인해 손쉽게 이미지나 동영상을 만들 수 있게 되었다. 이를 통해 거짓 정보를 만들어 퍼뜨리거나 신원을 도용하는 등 악용하는 사례가 발생함에 따라 데이터 조작은 나날이 더 큰 위협으로 그 문제의 심각성이 대두되고 있다.[1] 이러한 기술은 사람의 눈으로도 구별할 수 없는 고품질의 가짜 동영상을 생성할 수 있기 때문에 악의적인 목적에 의해 쉽게 악용되어 심각한 사회 문제나 정치적 위협을 초래할 수 있기 때문에 이러한 문제들을 해결하기 위해 많은 연구들이 진행 중이다.[2]

CNN(Convolutional Neural Networks)은 이미지 분석 작업에서 광범위하게 사용되는 딥러닝 네트워크 아키텍처이다. CNN을 기반으로 생성한 네트워크 모델은 이미지의 복잡한 특성을 자동으로 학습하고 특징을 추출하며, 계산 효율성과 범용성 등의 장점을 가지고 있어 이미지 관련 작업에서 널리 사용되고 있다.

자연어 처리에서 만들어진 Attention 알고리즘을 통해 CNN에 적용하여 이미지 내 특징점(Keypoints)이 되는 부분을 강조하여 이미지 분류 분야에서 높은 성능을 보인다.[3] 이러한 Attention 알고리즘 외에도 2개의 분기(Two-Branch) 네트워크 구조로로 병렬 계산을 통해 효율성을 향상시키는 방법들이 있다. 이러한 네트워크 구조는 각 분기를 독립적으로 설계할 수 있고 최적화를 수행할 수 있으므로 네트워크 아키텍처의 유연성을 증가시키는데 도움이 된다.[4]

이러한 2개의 분기를 가진 네트워크 아키텍처는 저주파 컨텍스트(Low-Frequency Context)를 묻힐 수 있다는 한계를 지적하며 제안된 PIDNet은 3 개의 분기를 가진 네트워크 아키텍처를 제안하여 최근 가장 좋은 성능을 보이고 있다. [5]

CNN을 통한 네트워크 아키텍처의 목적(Downstream)는 주어진 데이터에서 정답을 찾는 것이다. 하지만, 생성형 AI의 근간이 되는 네트워크는 기존 데이터의 분포를

학습한 네트워크 아키텍처가 그 분포와 유사한 새로운 데이터를 만들어낸다는 점에서 차이가 있다.

VAE(Variational Auto Encoder) 또한 유사한 새로운 데이터들을 만들어내는 것을 목적으로 한다. 하지만, 실제 데이터의 분포는 다양하고 다루기 어려운 복잡한 분포를 가지는 경우가 많아 잘 알려지고 다루기 쉬운 가우시안(Gaussian) 등의 분포를 가정하고 이를 찾는 방식으로 학습을 진행한다.[7] 하지만, 가우시안 등의 분포로 가정하였기 때문에 생성된 결과물은 분포의 평균값으로 수렴하여 항상 흐릿한 이미지가 생성된다.

적대적(adversarial) 학습 방식을 사용하는 GAN(Generative Adversarial Network)은 데이터를 생성하는 Generator와 이를 구별하는 Discriminator의 두 모델 간의 서로를 속이는 방식으로 학습을 진행한다.[8] Discriminator를 속이는 방식으로 학습하였기에 다양한 이미지를 생성하지 못하고 비슷한 이미지만 계속 생성하는 Mode Collapse에 빠질 위험이 있다.

Diffusion 네트워크 아키텍처는 노이즈가 섞인 이미지에서 원래의 이미지를 완벽하게 복원하는 것은 불가능하지만 비슷한 새로운 이미지를 만들어 낼 수 있다는 점을 활용한다. 원본 이미지에 노이즈를 추가하는 Forward process와 잠재 변수(latent variable)로부터 이미지를 복원하는 Reverse process로 구분한다.[9] 이러한 Diffusion 네트워크 아키텍처는 최근 큰 관심을 받고 있는 생성형 AI인 Stable Diffusion의 근간이다.

최근 오늘날 생성형 AI로 만들어낸 이미지는 실제 촬영한 이미지와 구별하기 힘든 상황에 이르렀다. 본 논문에서는 악의적인 목적으로 생성형 AI를 통해 만들어낸 이미지를 판별하는 기법을 제안한다.

Ⅱ. 제안하는 방법

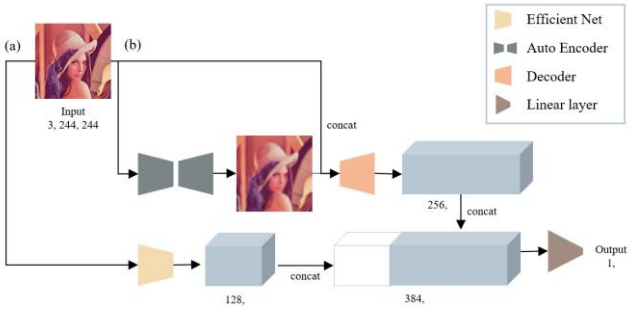

그림 1. 제안하는 네트워크

본 논문에서는 생성형 AI로 만들어낸 이미지를 판별하기 위한 네트워크를 제안한다. 제안하는 네트워크는 그림 1과 같다. 그림 1. (a)에서 Efficient Net[10]은 입력 이미지를 실제 이미지와 만들어낸 이미지를 잘 분류할 수 있기를 기대한다. 그리고 그림 1. (b)에서 Auto Encoder를 통과한 입력 이미지는 실제 이미지와 최대한 비슷하게, 만들어낸 이미지와 다르게 복원되길 기대한다.

식 1은 제안하는 네트워크의 손실(loss) 함수로 BCE(Binary Cross Entropy)와 MSE(Mean Squared Error)를 조합한다. 만들어낸 이미지(fake)의 경우, Auto Encoder를 통과한 결과가 입력 이미지와 같으면 MSE의 결과 값이 0에 가까워지기 때문에 높은 손실을 유도하기 위해 식 1. (2-b), (2-c) 와 같이 inverted sigmoid를 적용한다.

$$L = L_{bce} + \alpha * L_{bce_{real}} + \beta * L_{bce_fake} \quad (1)$$

$$L_{bce_real} = L_{mse}(pred_{real}, label_{real}) \quad (2\text{-a})$$

$$L_{bce_fake} = sigmoid_{inverted}\left(L_{mse}(pred_{fake}, label_{fake})\right) \quad (2\text{-b})$$

$$sigmoid_{inverted} = \frac{2}{1 + \exp(x)} \quad (2\text{-b})$$

<식 1> 제안하는 Loss function

Ⅲ. 실험 결과 및 결론

객관적인 성능 평가를 위해, 관련 경진대회에서 제공하는 데이터셋[11]을 사용한다. 데이터셋은 다양한 해상도로 구성되어 있으며 만든 이미지와 실제 이미지는 각각 10,000개씩 구성되어 있다. 평가를 위한 테스트 데이터셋 또한 10,000개이며 정답은 기재되어 있지 않기 때문에 경진 대회 리더보드를 통해 확인이 가능하다. 평가 지표로 F1 Score를 사용한다. 해당 지표는 식 2와 같다. 리더보드를 통해 확인한 결과로 F1 Score 0.9023을 얻었다.

$$F1\ \ Score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

<식 2> F1 Score

참 고 문 헌

[1] Lubna, J. I., & Chowdhury, S. A. K. (2019, December). Detecting Fake Image: A Review for Stopping Image Manipulation. In International Conference on Computational Intelligence, Security and Internet of Things (pp. 146-159). Singapore: Springer Singapore.

[2] Zhao, H., Zhou, W., Chen, D., Wei, T., Zhang, W., & Yu, N. (2021). Multi-attentional deepfake detection. In Proceedings

of the IEEE/CVF conference on computer vision and pattern recognition (pp. 2185-2194).

[3] Wang, F., Jiang, M., Qian, C., Yang, S., Li, C., Zhang, H., ... & Tang, X. (2017). Residual attention network for image classification. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 3156-3164).

[4] Bertinetto, L., Valmadre, J., Henriques, J. F., Vedaldi, A., & Torr, P. H. (2016). Fully-convolutional siamese networks for object tracking. In Computer Vision–ECCV 2016 Workshops: Amsterdam, The Netherlands, October 8-10 and 15-16, 2016, Proceedings, Part II 14 (pp. 850-865). Springer International Publishing.

[5] Xu, J., Xiong, Z., & Bhattacharyya, S. P. (2023). PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 19529-19539).

[7] Kingma, D. P., & Welling, M. (2013). Auto-encoding variational bayes. arXiv preprint arXiv:1312.6114.

[8] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2020). Generative adversarial networks. Communications of the ACM, 63(11), 139-144.

[9] Ho, J., Jain, A., & Abbeel, P. (2020). Denoising diffusion probabilistic models. Advances in neural information processing systems, 33, 6840-6851.

[10] Tan, M., & Le, Q. (2019, May). Efficientnet: Rethinking model scaling for convolutional neural networks. In International conference on machine learning (pp. 6105-6114). PMLR.

[11] Fake or Real: AI생성 이미지 판별 경진대회 데이터셋, (https://aiconnect.kr/competition/detail/227/task/295/data)